HTTPS://GITHUB.COM/ARPITA-DEB/NETFLIX-MOVIES-AND-TV-SHOWS

Ziel der Analyse

Rahmen und Zielsetzung des SQL-Abschlussprojekts

1

Datenmodell aufbauen

Rohdaten in eine relationale Struktur überführen

2

Inhalte analysieren

Strukturen, Verteilungen und Trends untersuchen

3

Erkenntnisse ableiten

SQL-basierte Ergebnisse fachlich interpretieren

Rohdaten → Datenmodell → SQL-Analyse → Erkenntnisse

Methodisches Vorgehen

Vom Rohdatensatz zum analysefähigen Datenmodell

Datenvorbereitung

1 Rohdaten analysiert

Relevante Tabellen und Attribute identifiziert

2 Daten bereinigt

Datentypen, Spalten und Werte vereinheitlicht

3 Daten importiert

Bereinigte CSV-Dateien nach PostgreSQL übernommen

Modellierung & Analyse

4 Datenmodell aufgebaut

Tabellen normalisiert, Beziehungen und Schlüssel definiert

5 Analyse vorbereitet

Views erstellt und Ergebnisse visualisiert

Datenverständnis und Datenqualität

Zentrale Herausforderungen des Rohdatensatzes

Herausforderungen im Rohdatensatz

- Mehrfachwerte in Genre, Country, Actor und Director
- Fehlende oder uneinheitliche Werte
- Rohdaten nicht direkt analysefähig
- Plausibilitätsprüfung einzelner Werte

Umsetzung im Projekt

- Auflösung mehrwertiger Attribute in Beziehungstabellen
- Vereinheitlichung von Datentypen und Attributen
- Aufbau eines relationalen Modells
- Kontrollabfragen zur Qualitätssicherung

Die Daten mussten vor der Analyse strukturell und inhaltlich aufbereitet werden

Analyseschwerpunkte

Zentrale Fragestellungen auf Basis des finalen Datenmodells

NETFLIX

Katalogstruktur

Inhalte nach Typ
Top-Genres
Top-10-Länder

Zeitliche Entwicklung

Veröffentlichungsjahre
Genre-Trends
Filme und Serien im Zeitverlauf

Vertiefende Analysen

Laufzeiten / Staffeln
IMDb-Bewertungen
Zielgruppenstruktur

Herleitung des ER-Diagramms

Begründung der zentralen Tabellen und Beziehungen im finalen Datenmodell

Entität bzw. Beziehung	Begründung	Umsetzung im Modell
title	Zentrale Tabelle mit allen Inhalten wie Filmen und Serien	Haupttabelle
title_type	Typen wie Movie oder Show wiederholen sich mehrfach	1:n Beziehung zu title
age_certification	Altersfreigaben treten bei vielen Titeln wiederholt auf	1:n Beziehung zu title
genre	Ein Titel kann mehreren Genres zugeordnet sein	M:n Beziehung über title_genre
country	Ein Titel kann mit mehreren Produktionsländern verknüpft sein	M:n Beziehung über title_country
actor	Ein Schauspieler kann in mehreren Titeln mitwirken	M:n Beziehung über title_actor
director	Ein Regisseur kann mehrere Titel verantworten	M:n Beziehung über title_director

1:n-Beziehungen: title_type, age_certification → Ein Titel hat genau einen Typ und eine Altersfreigabe
m:n-Beziehungen: genre, country, actor, director → Ein Titel kann mehrere Genres / Länder / Beteiligte haben

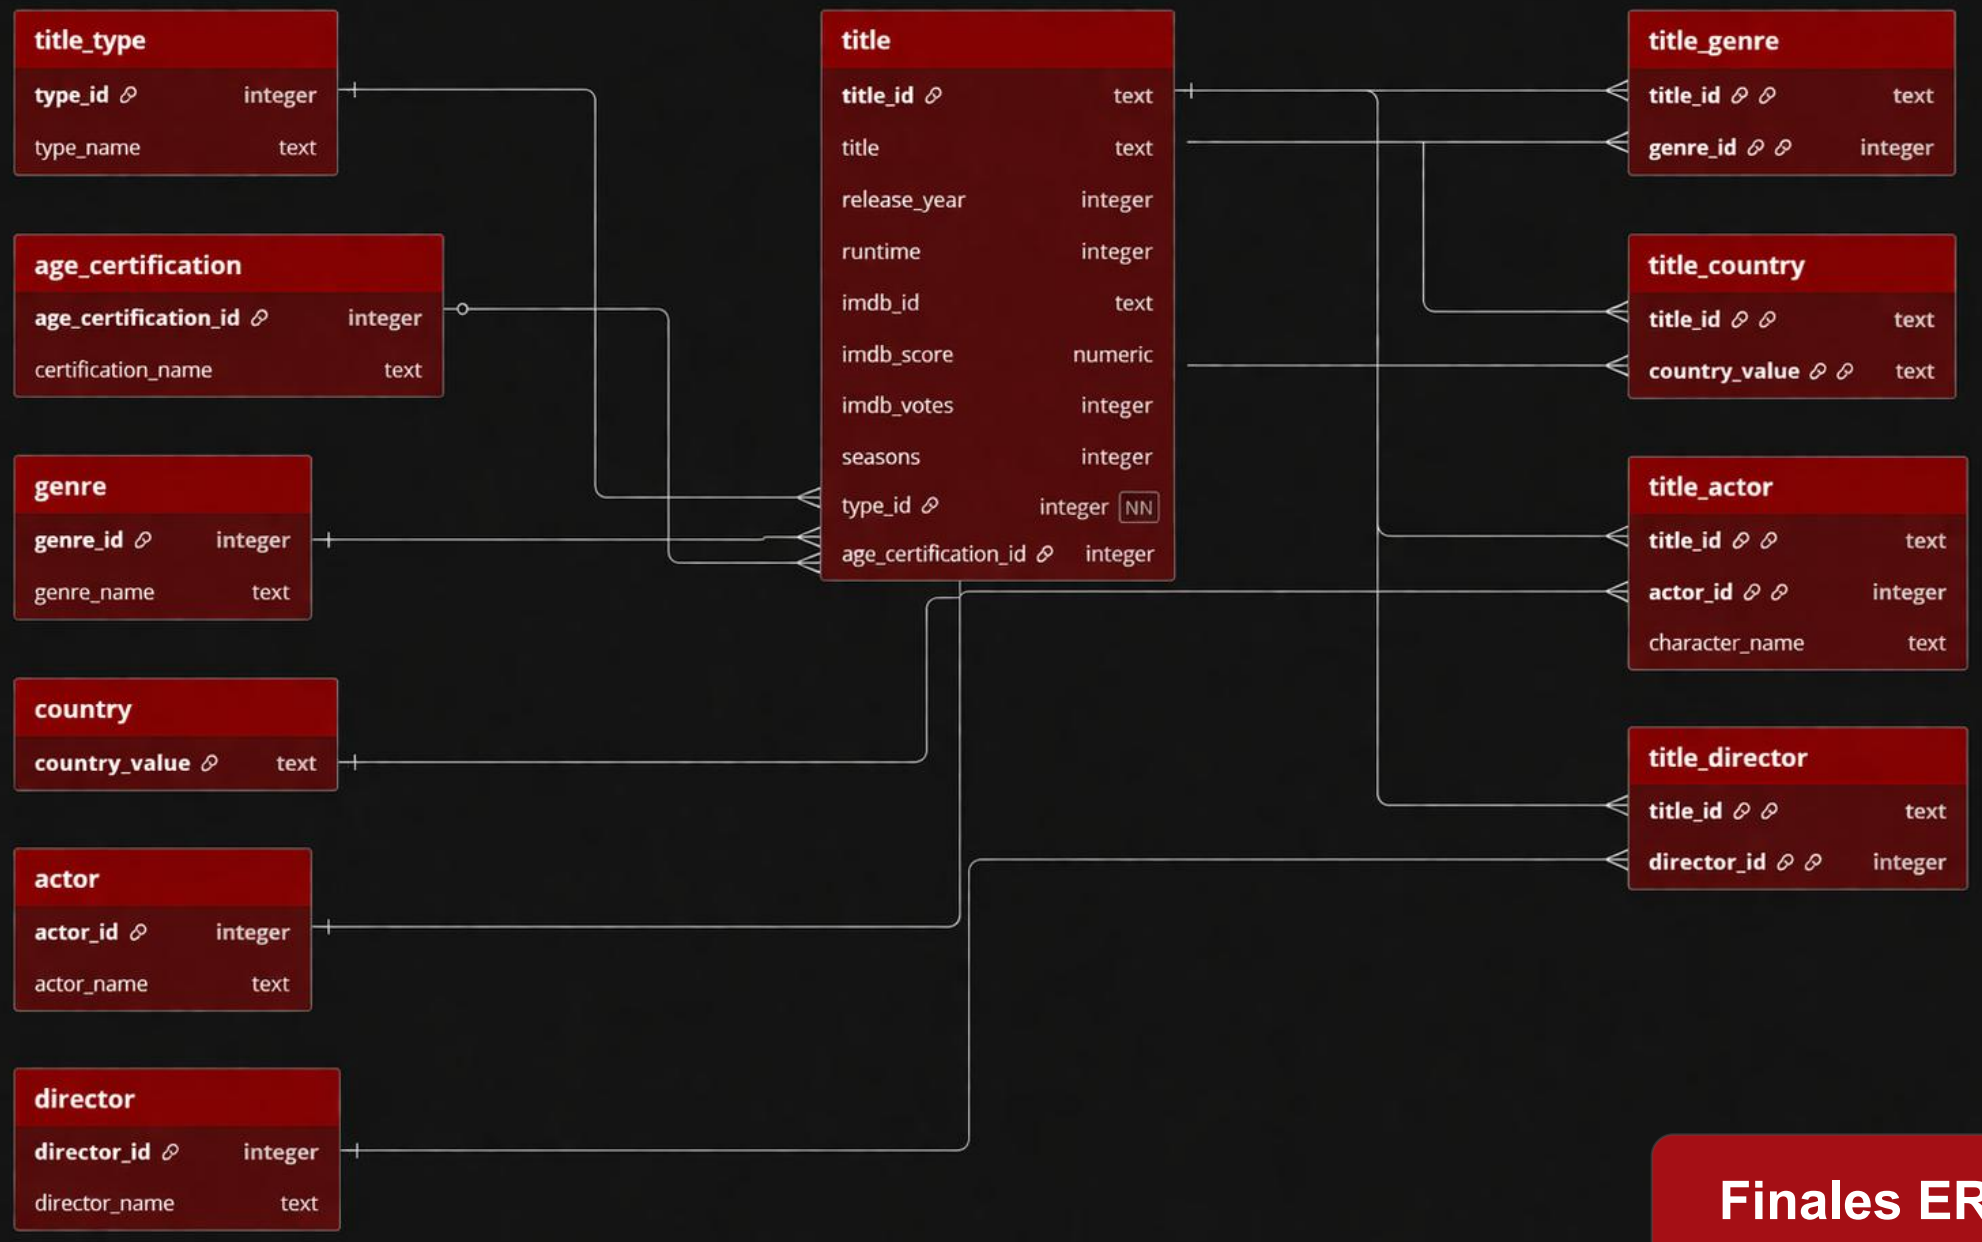
title_type
type_id integer
type_name text
age_certification
age_certification_id integer
certification_name text
genre
genre_id integer
genre_name text
country
country_value text
actor
actor_id integer
actor_name text
director
director_id integer
director_name text
title
title_id text
title text
release_year integer
runtime integer
imdb_id text
imdb_score numeric
imdb_votes integer
seasons integer
type_id integer NN
age_certification_id integer
title_genre
title_id text
genre_id integer
title_country
title_id text
country_value text
title_actor
title_id text
actor_id integer
character_name text
title_director
title_id text
director_id integer

Finales ERD

Verwendete Views für Standardauswertungen

Vorteil: Views kapseln häufig genutzte Logik und erleichtern wiederkehrende Standardauswertungen.

View	Zweck
vw_titles_per_year	Anzahl der Inhalte pro Veröffentlichungsjahr
vw_genre_counts	Häufigkeit der Genres im Datensatz
vw_titles_by_type	Verteilung nach Typ (Filme / Serien)

Filme vs. Serien

Auswertung auf Basis der View vw_titles_by_type

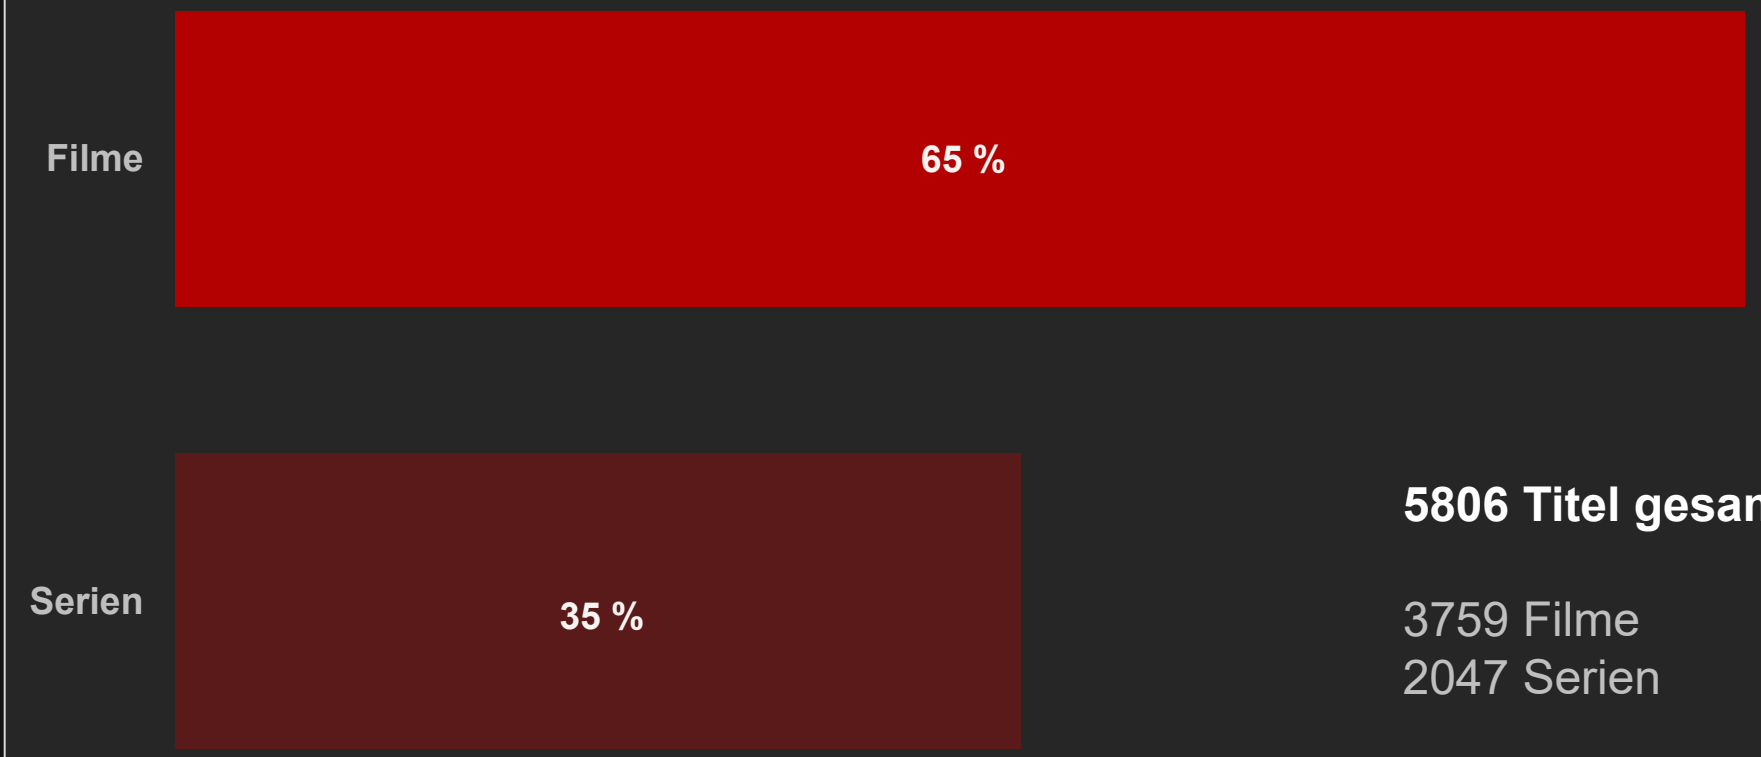

5806 Titel gesamt

3759 Filme
2047 Serien

Top-Genres nach Häufigkeit

Auswertung auf Basis der View vw_genre_counts

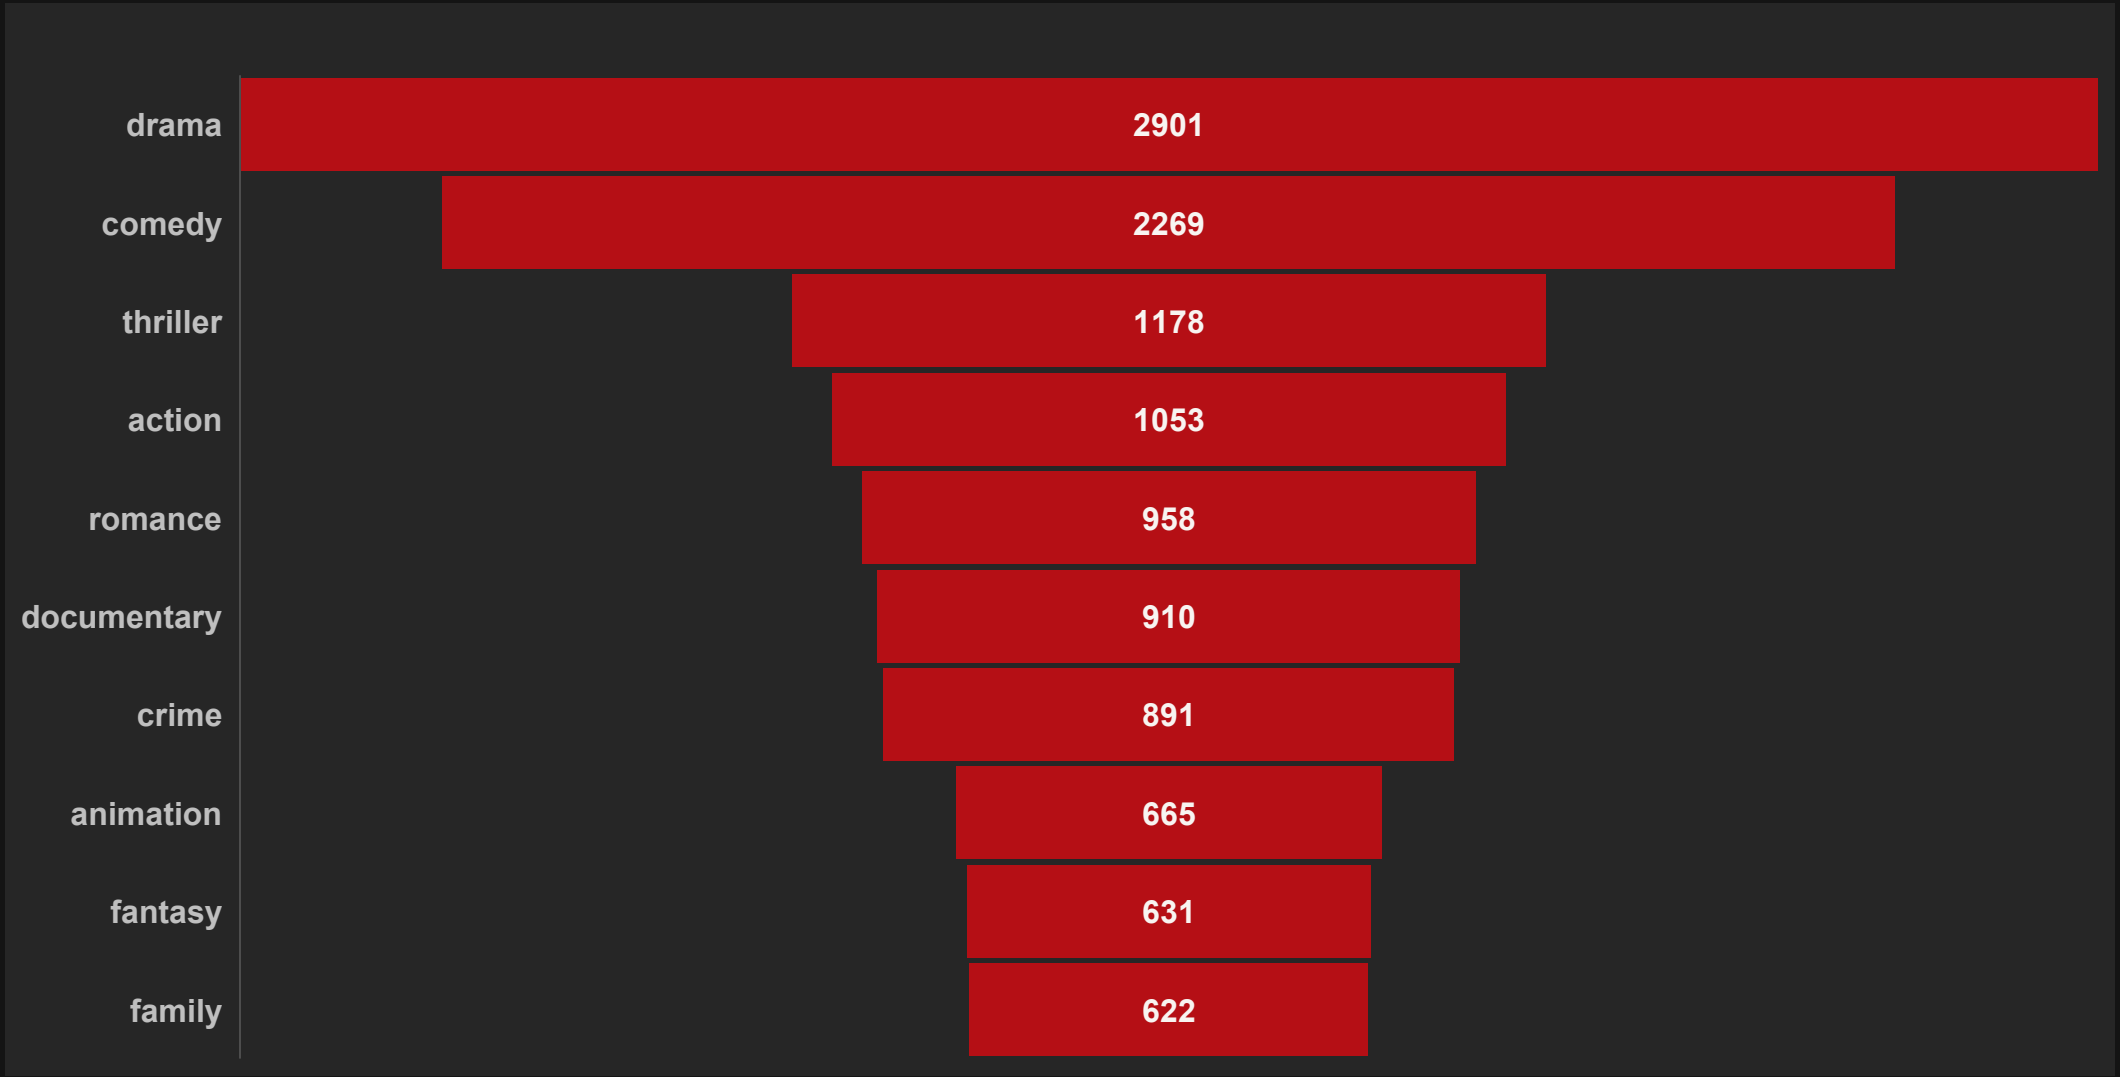

Ein Titel kann mehreren Genres zugeordnet sein.

Inhalte pro Veröffentlichungsjahr

Auswertung auf Basis der View vw_titles_per_year

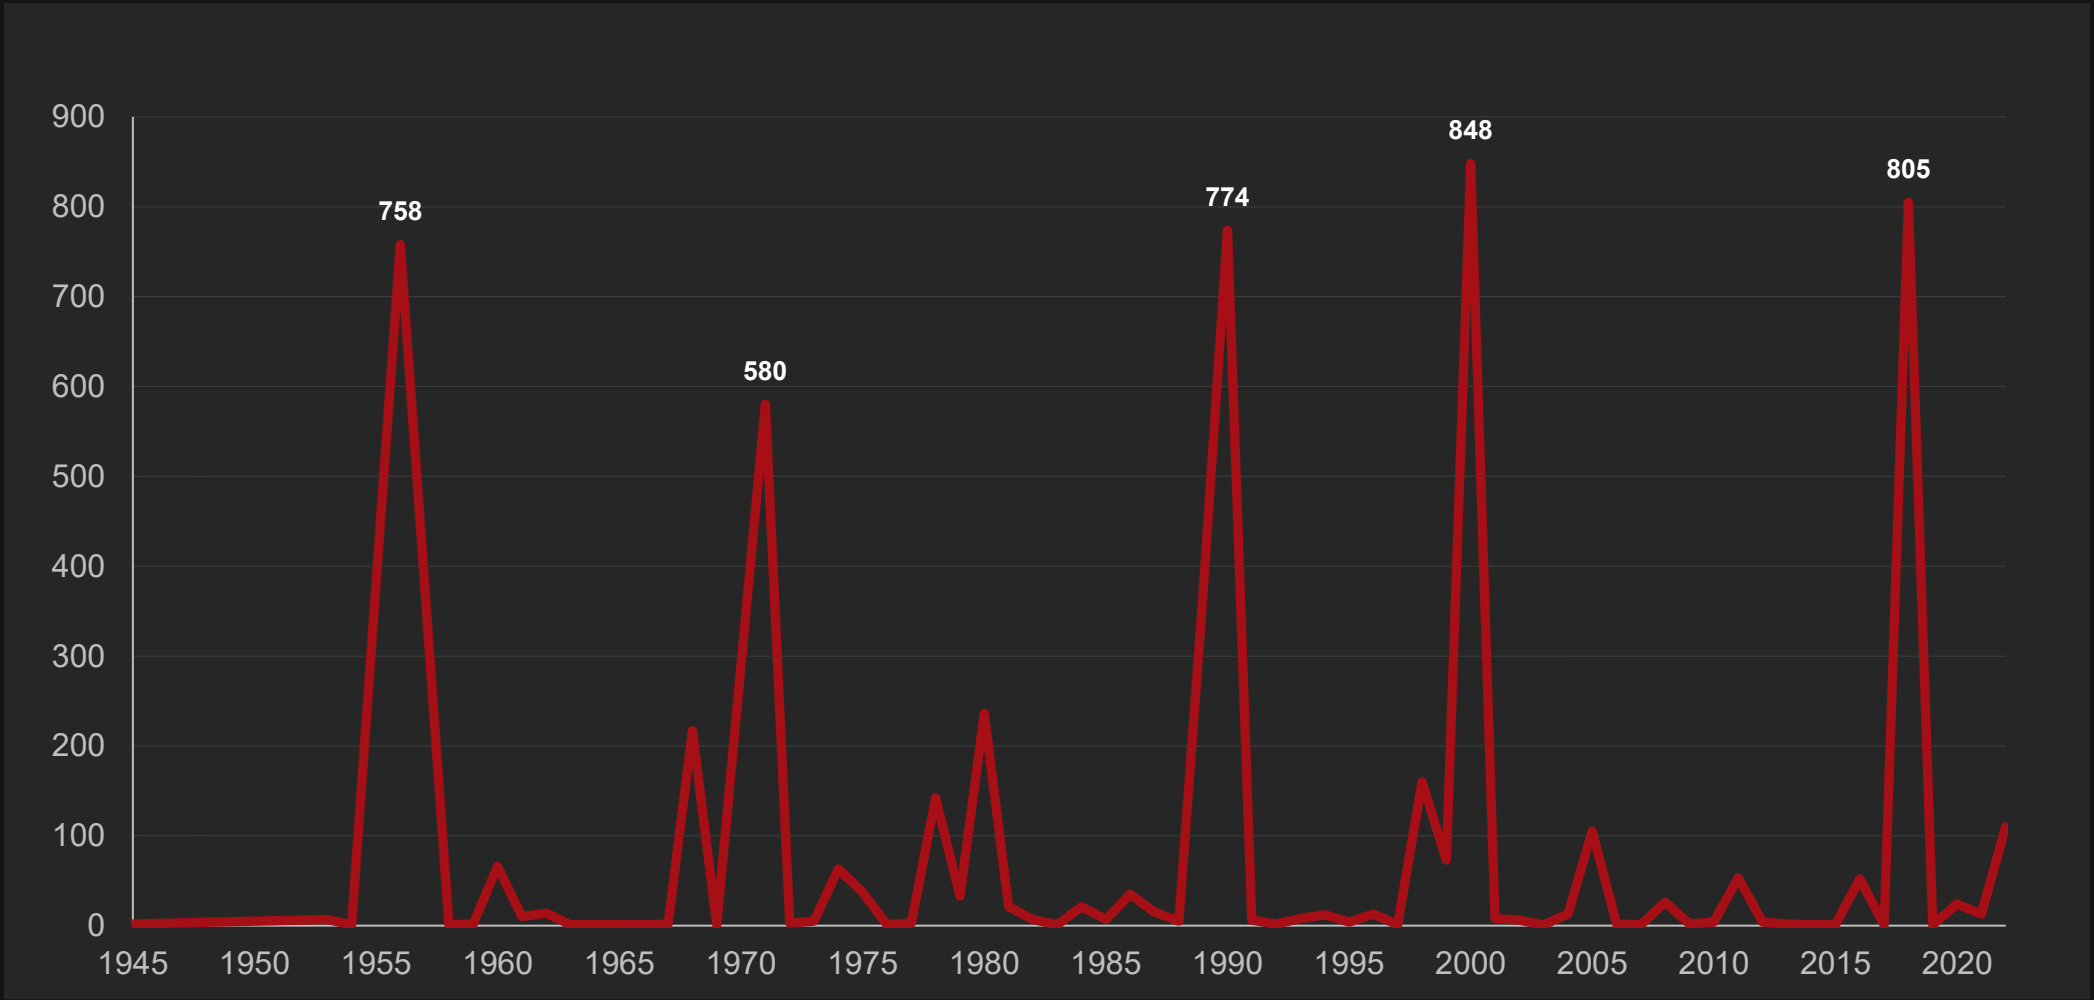

Der Katalog ist in neueren Jahren deutlich stärker vertreten.

Filme und Serien im Zeitverlauf

Entwicklung nach Inhaltstyp im Zeitraum 2011-2021

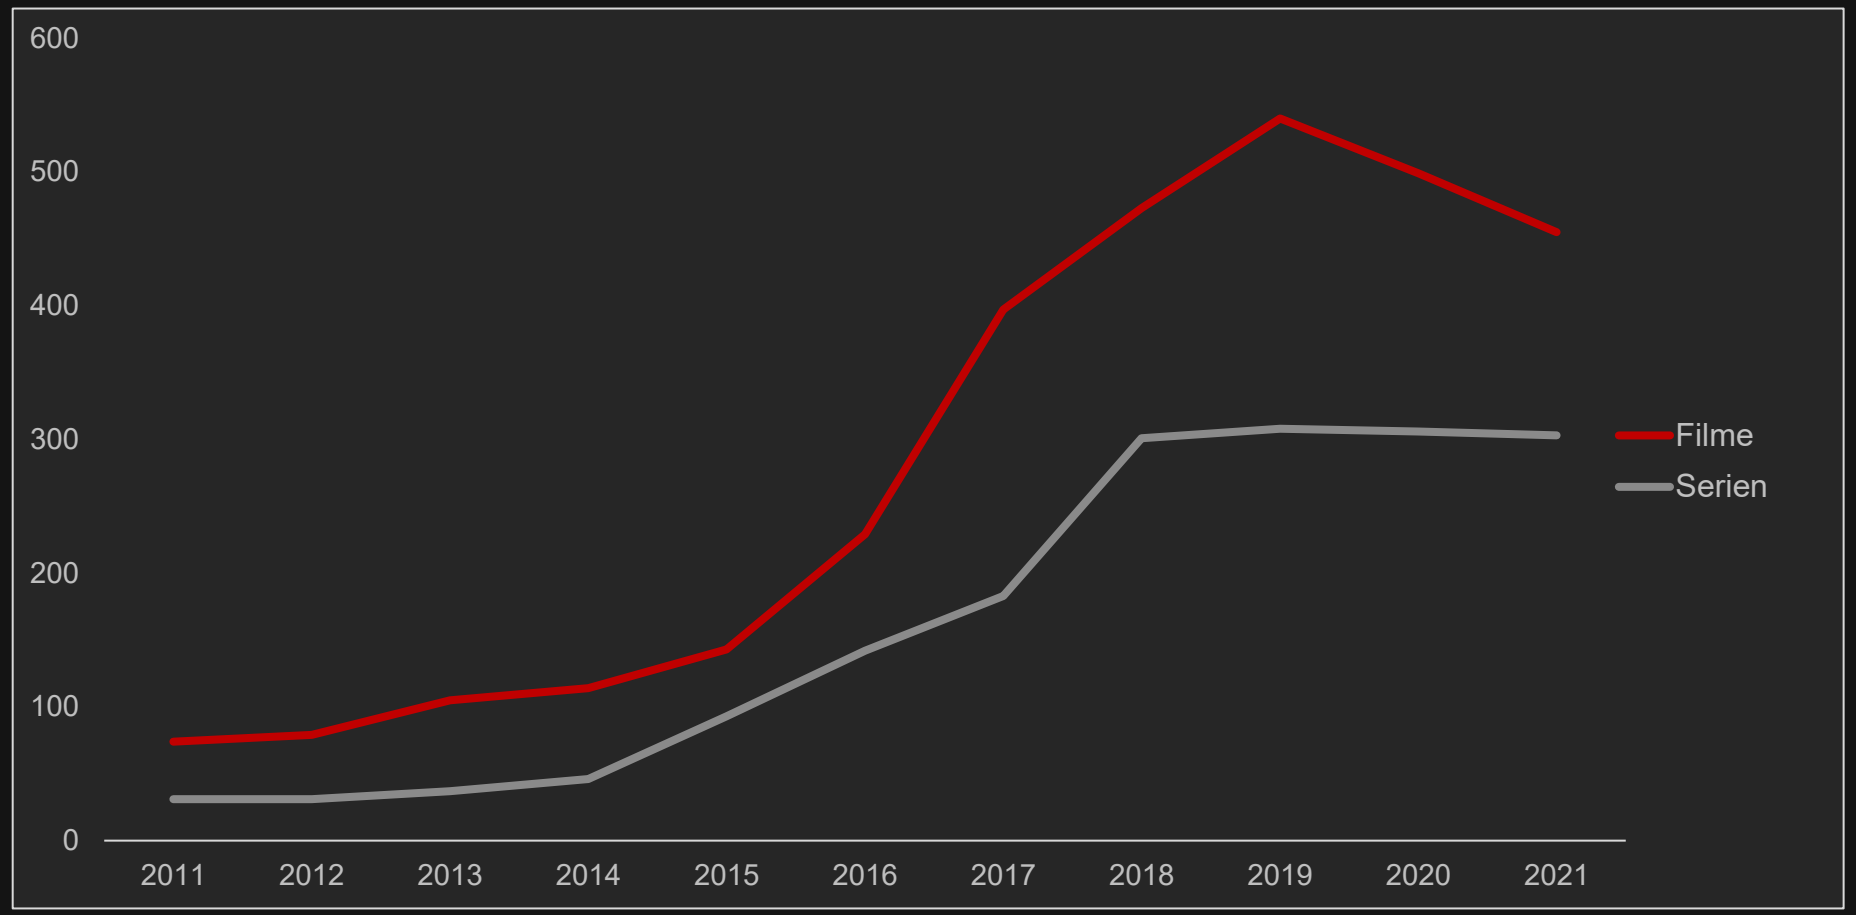

Filme dominieren im gesamten Zeitraum, Serien gewinnen ab Mitte der 2010er-Jahre jedoch deutlich an Bedeutung

Top-10-Länder im Netflix Katalog

Die USA dominieren den Datensatz deutlich vor Indien und Großbritannien.

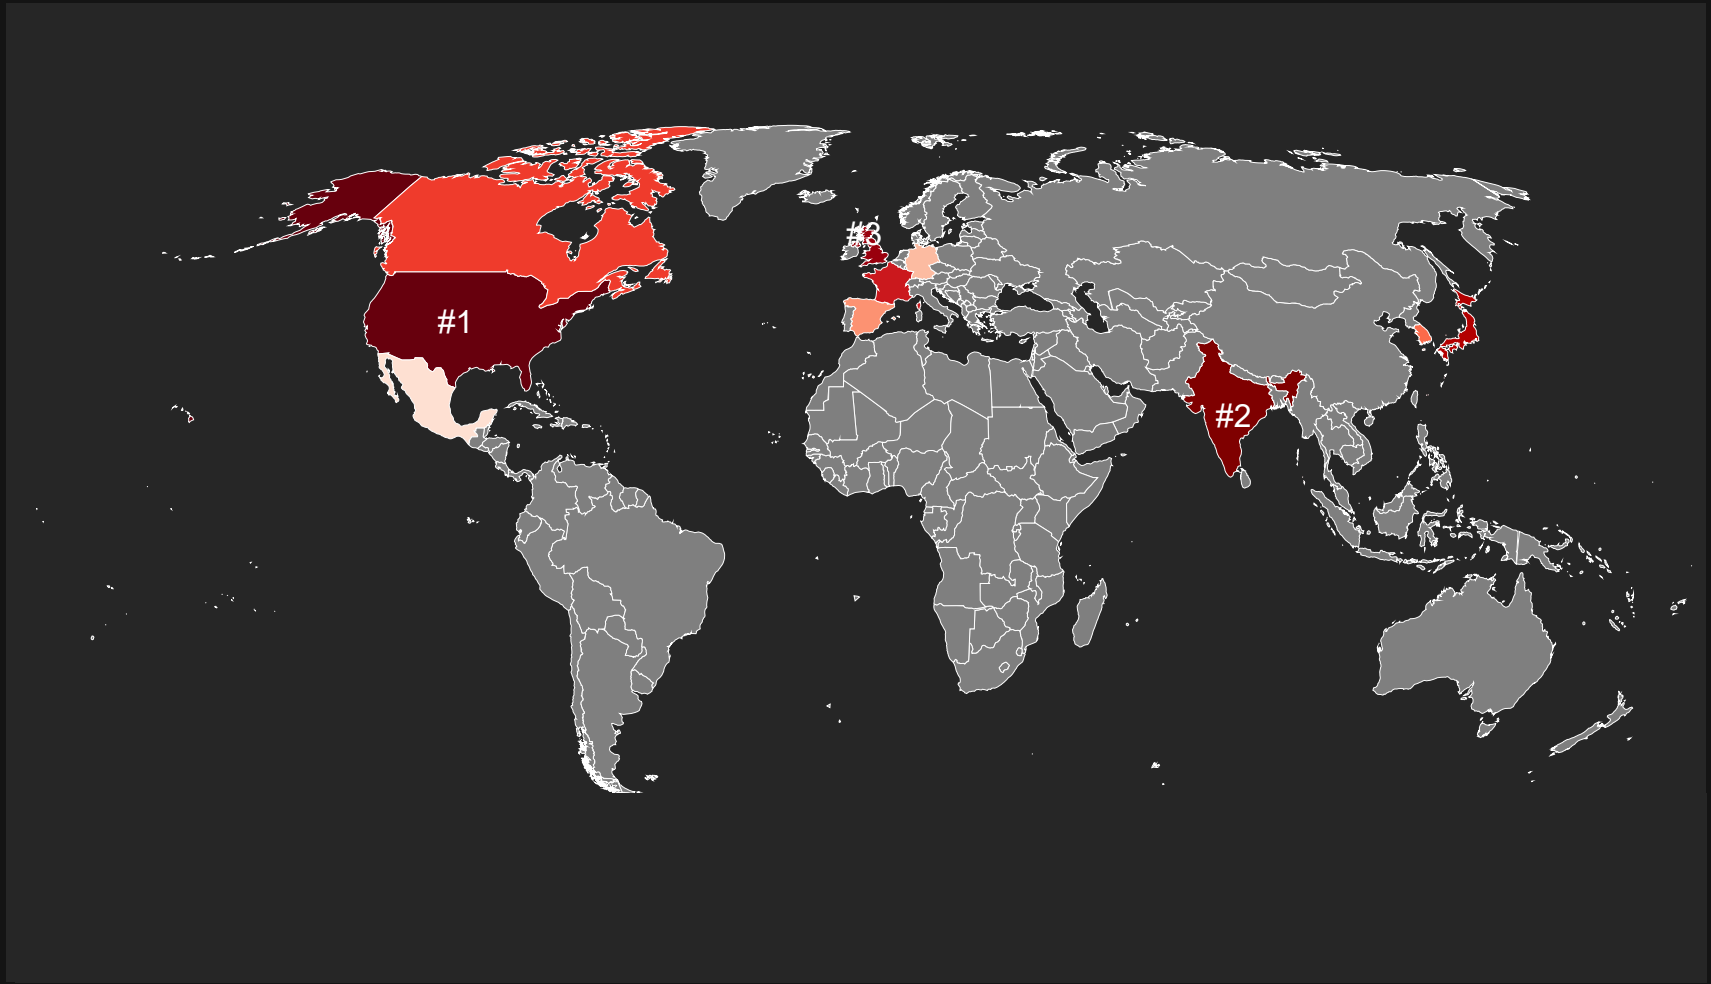

Top 10 Länder

1.	USA	2.327
2.	Indien	629
3.	Großbritannien	406
4.	Japan	291
5.	Frankreich	248
6.	Kanada	216
7.	Südkorea	216
8.	Spanien	212
9.	Deutschland	139
10.	Mexiko	123

Mehrfachzuordnungen pro Titel möglich.

Quelle: SQL-Auswertung des Netflix-Datensatzes

Top-Länder und hoch bewertete Titel

Die volumenstärksten Herkunftsländer lassen sich exemplarisch auch anhand einzelner hoch bewerteter Titel einordnen

Hochbewertete Titel pro Land

USA	Breaking Bad	Serie IMDb 9,5
Indien	Delhi Crime	Serie IMDb 8,5
Großbritannien	Sherlock	Serie IMDb 9,1

Top 3 Länder

1.	USA	2.327
2.	Indien	629
3.	Großbritannien	406

Basis: Anzahl zugeordneter Titel im Datensatz

Darstellung exemplarisch, basierend auf dem höchsten IMDb-Score je Land

Zwischenfazit

Zentrale Erkenntnisse aus den bisherigen SQL-Auswertungen

Filme dominieren

65 % Filme
35 % Serien

Drama und Comedy führen

häufigste Genres
im Datensatz

USA deutlich vorn

klarer Spitzenreiter im
Länderranking

Der Katalog ist filmzentriert, genreseitig konzentriert und länderseitig klar von den USA geprägt

Top-Regisseure nach Anzahl der Titel

SQL-Auswertung auf Basis des finalen Datenmodells

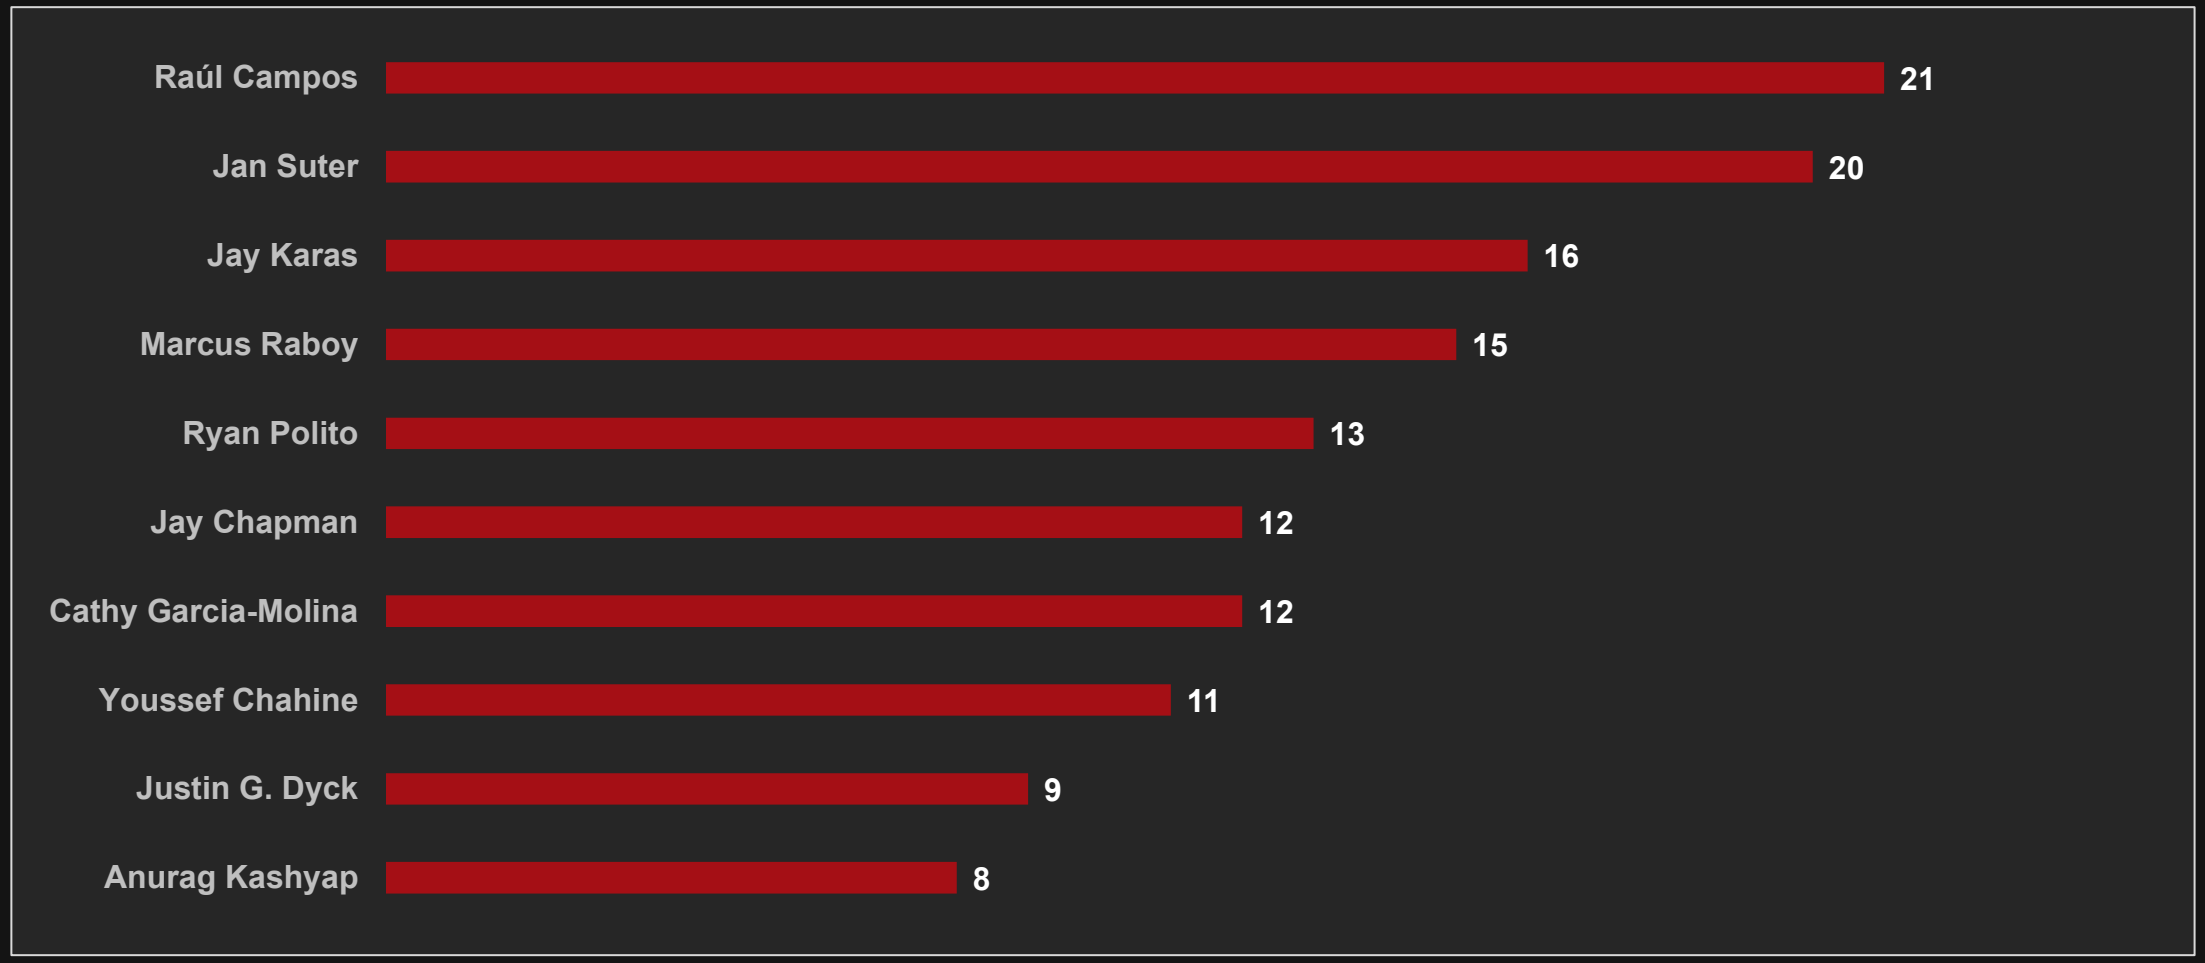

Die Spitze des Rankings ist relativ konzentriert, der Abstand nach unten nimmt schnell ab.

Längste Filme nach Laufzeit

SQL-Auswertung auf Basis des finalen Datenmodells

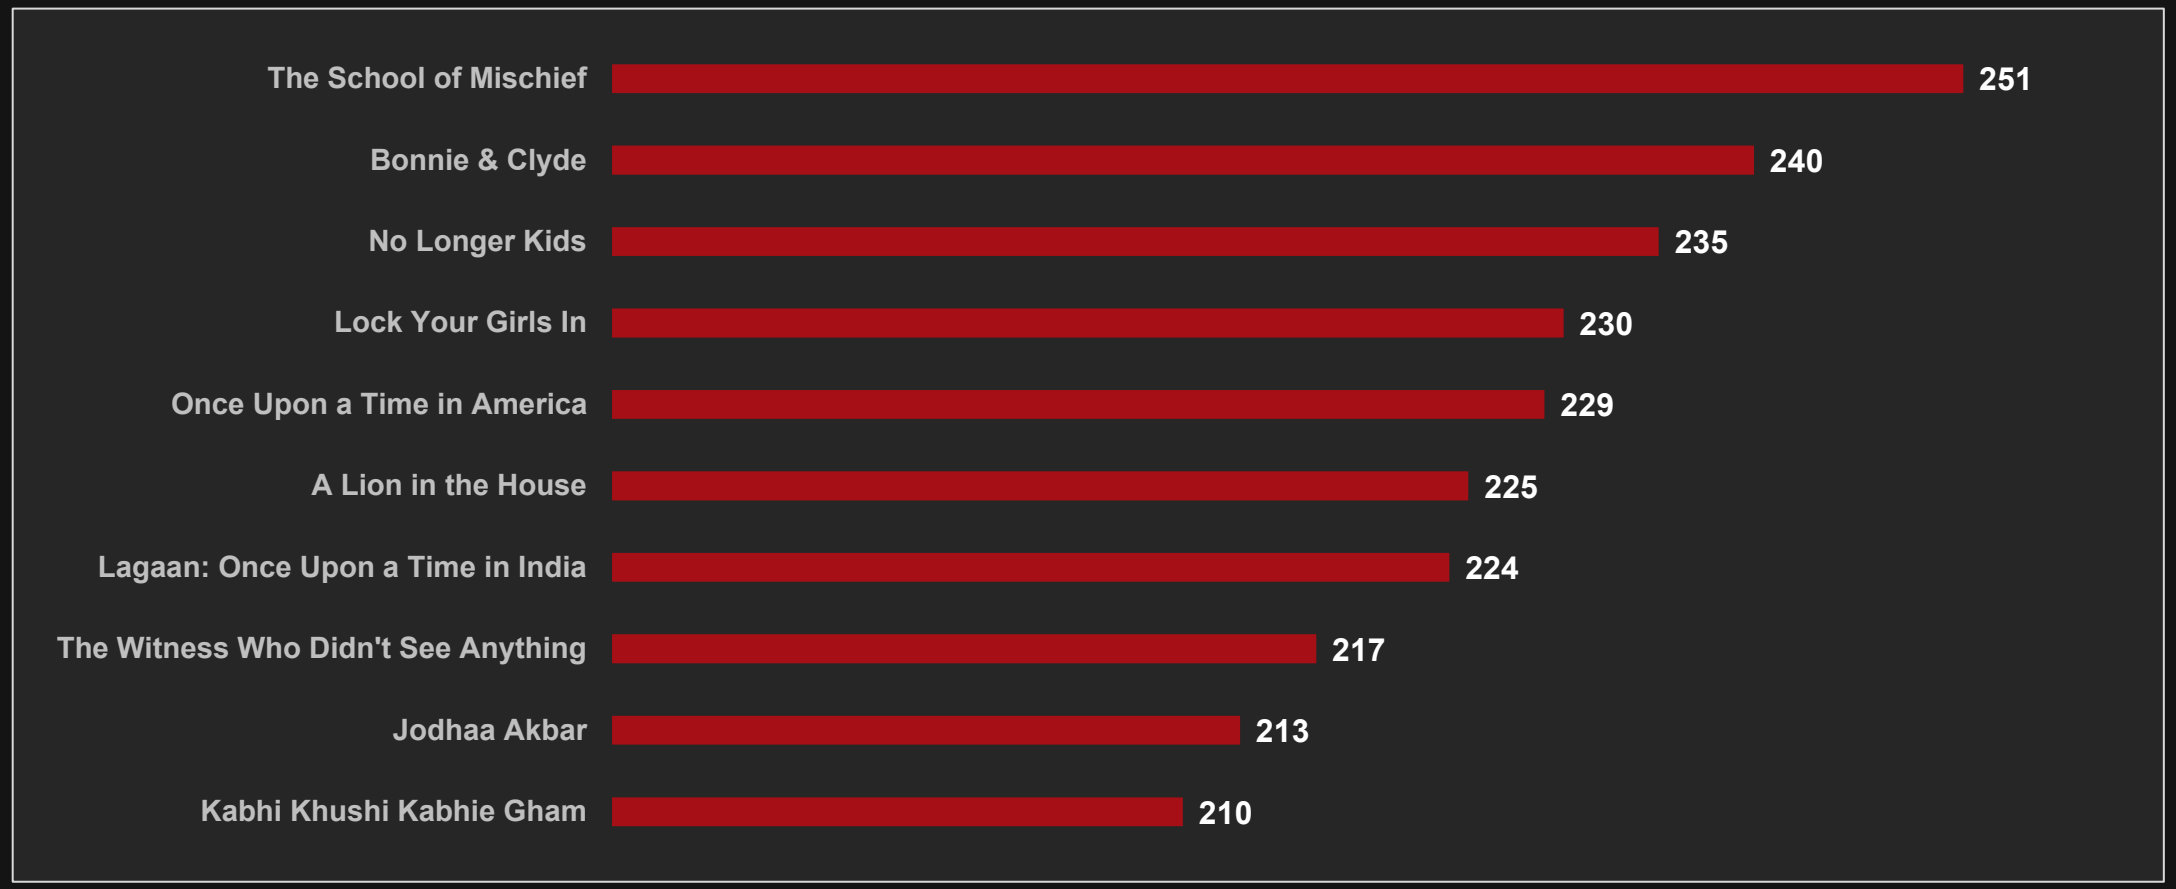

Die Spitzenwerte liegen deutlich über 200 Minuten und markieren klare Ausreißer im Datensatz.

Serien mit den meisten Staffeln

SQL-Auswertung auf Basis des finalen Datenmodells

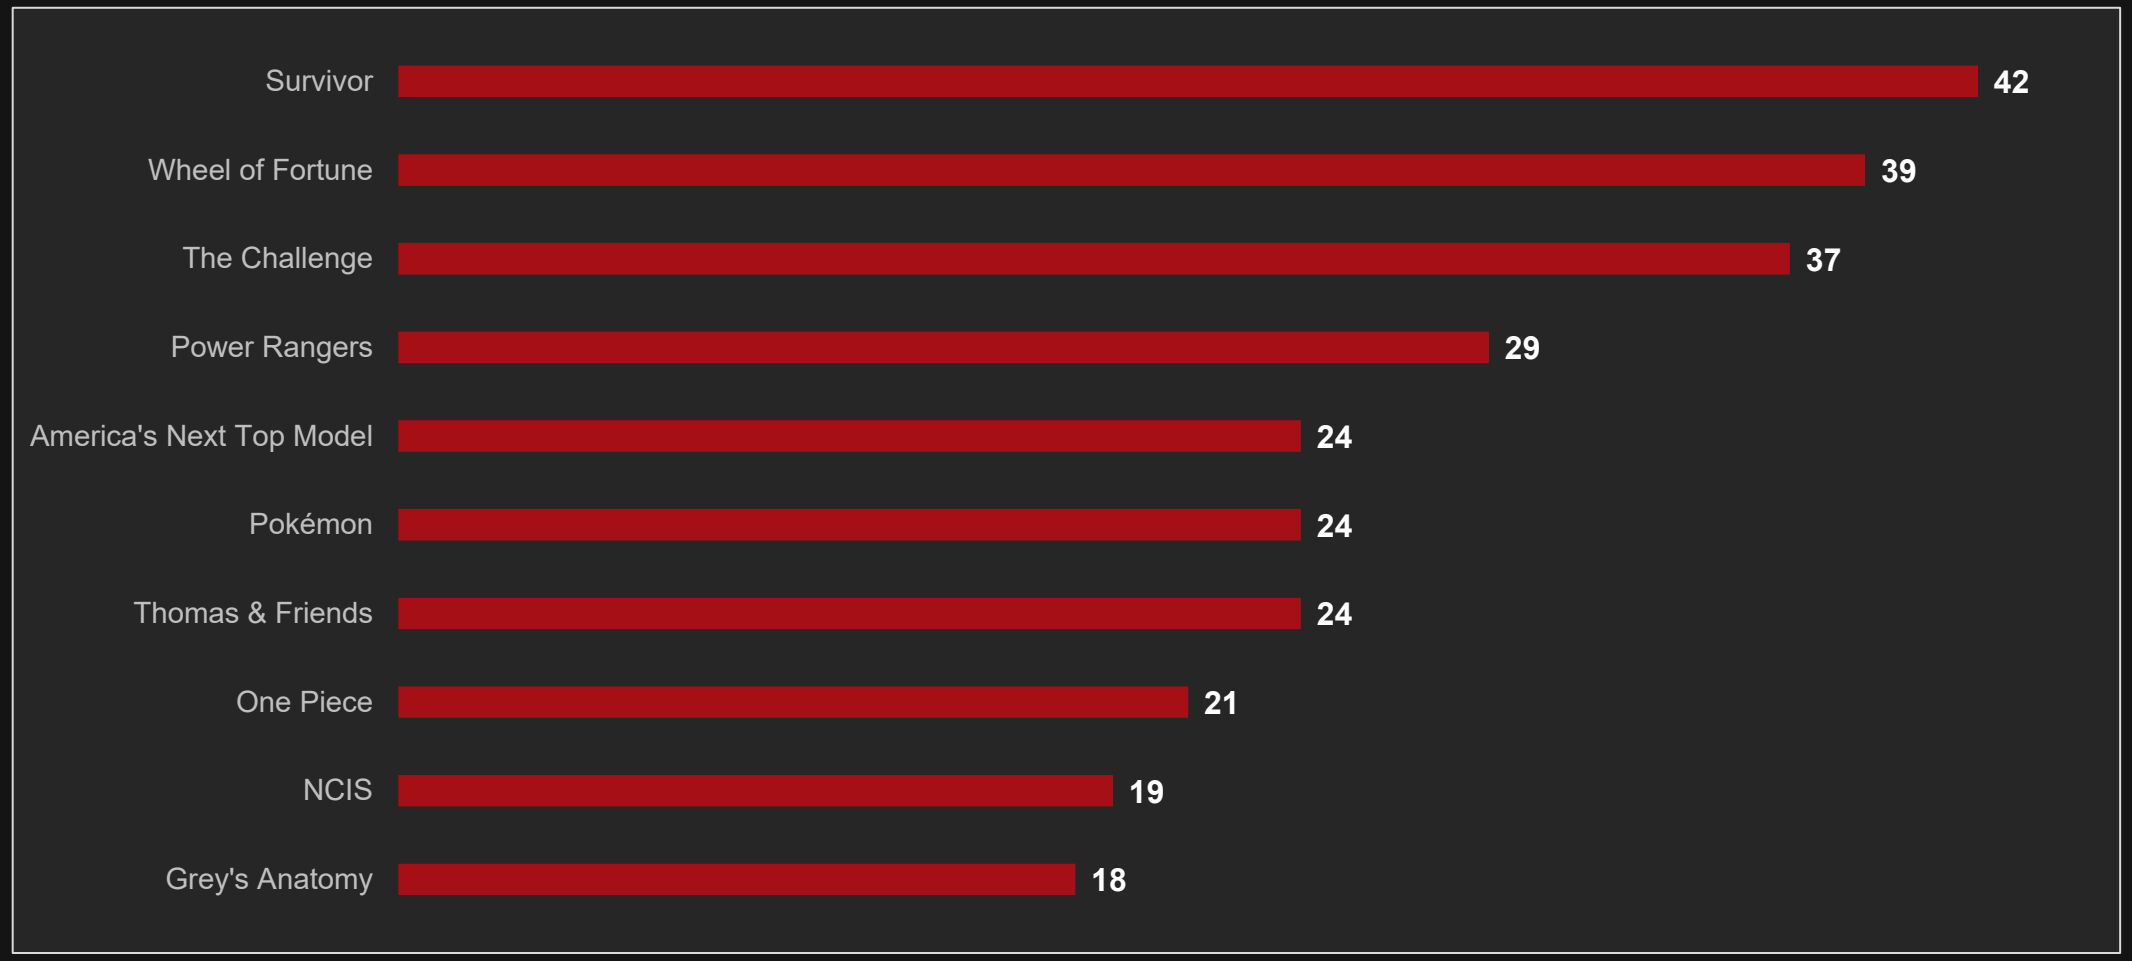

Die Staffelanzahl variiert stark und zeigt deutliche Ausreißer an der Spitze.
Staffelwerte wurden per Kontrollabfrage geprüft und bereinigt

Genre-Trends über die Zeit

Mainstream-Genres wie Drama und Comedy prägen die Entwicklung des Katalogs

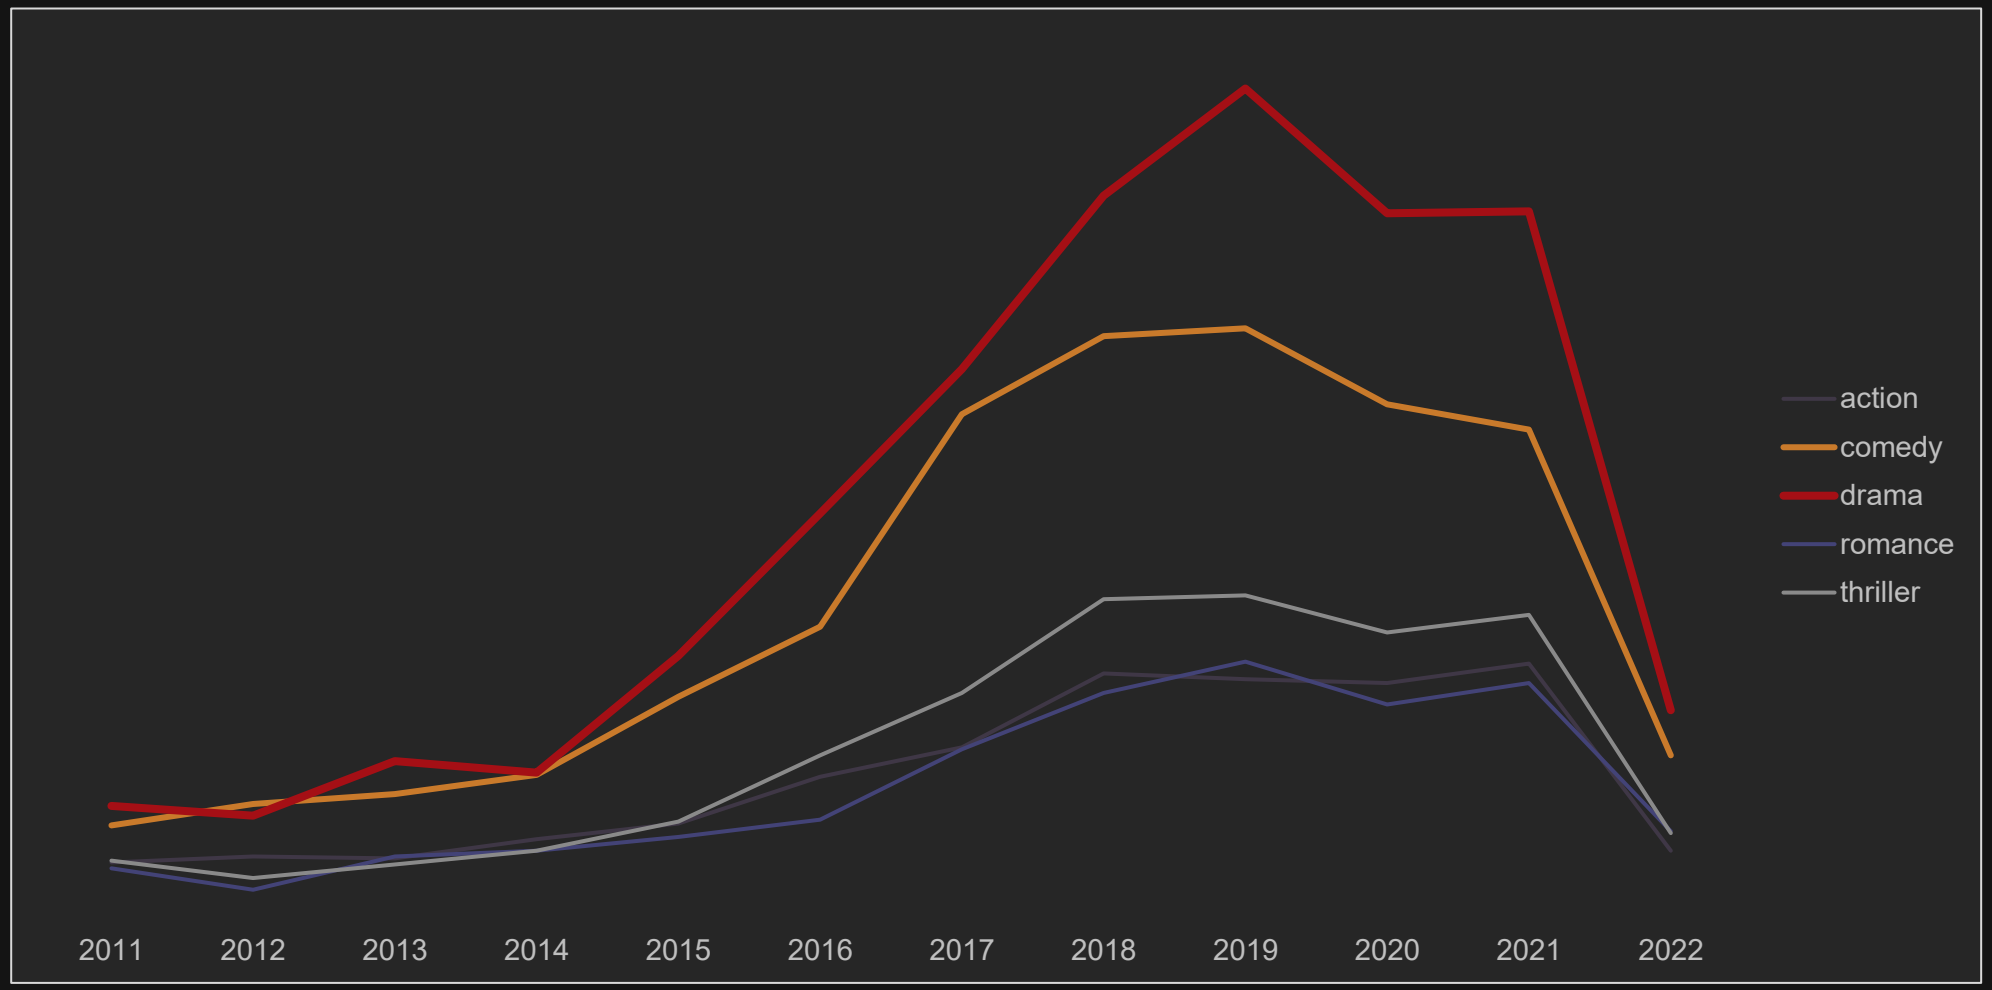

Genres mit den höchsten IMDb-Bewertungen

SQL-Auswertung auf Basis des finalen Datenmodells

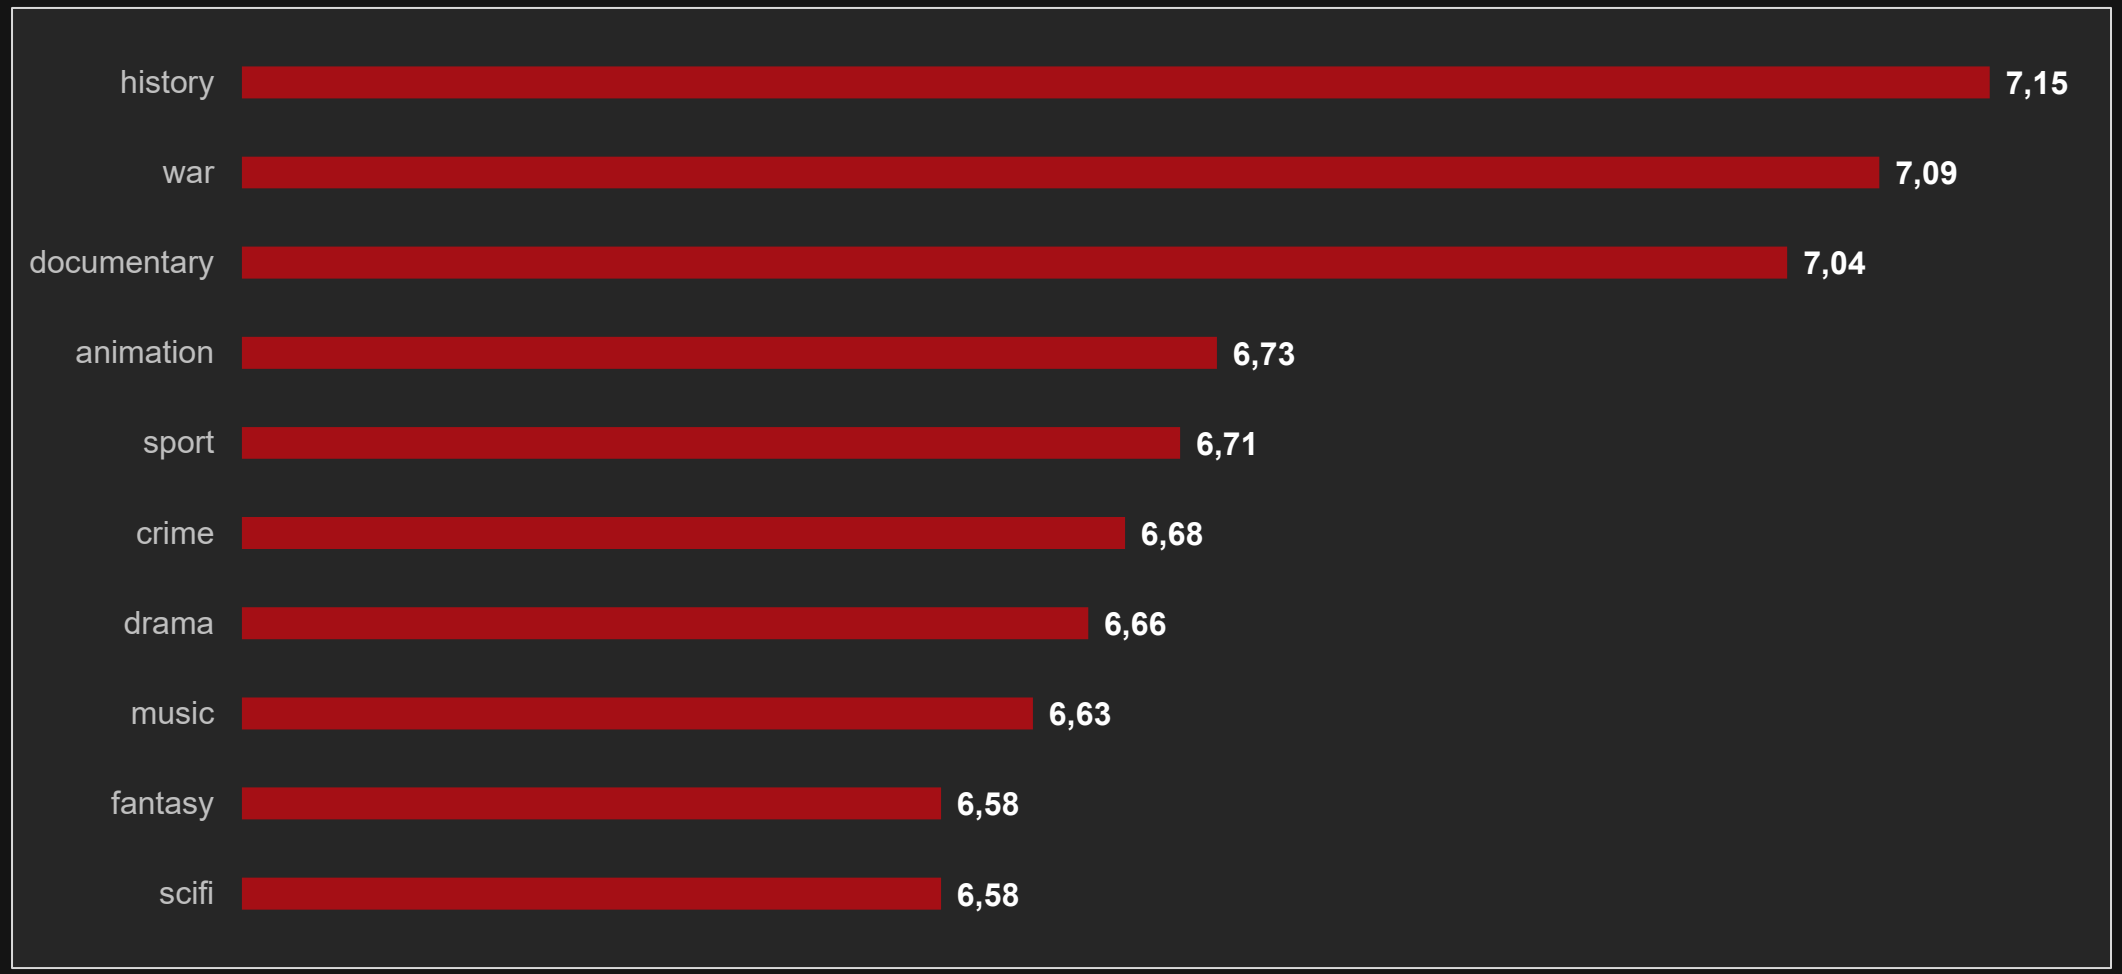

Historische, kriegsbezogene und dokumentarische Inhalte erzielen im Durchschnitt die höchsten IMDb-Bewertungen.

IMDb-Score = durchschnittliche Nutzerbewertung (0–10)
Nur Genres mit mindestens 50 Titeln berücksichtigt

Zielgruppenstruktur nach Altersfreigabe

SQL-Auswertung mit **CASE WHEN** zur Gruppierung der Altersfreigaben

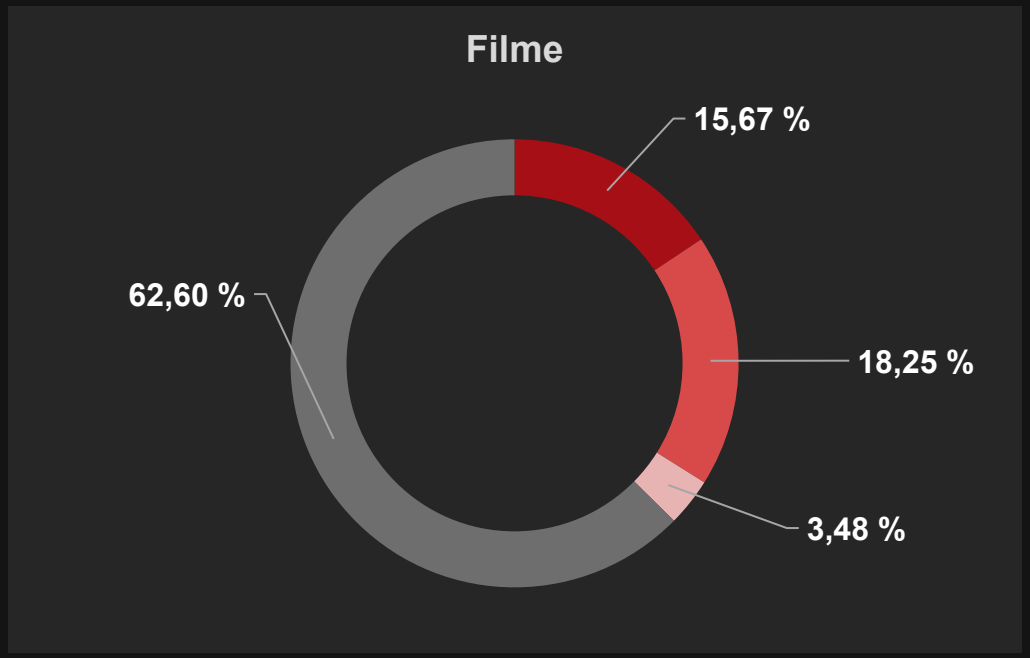

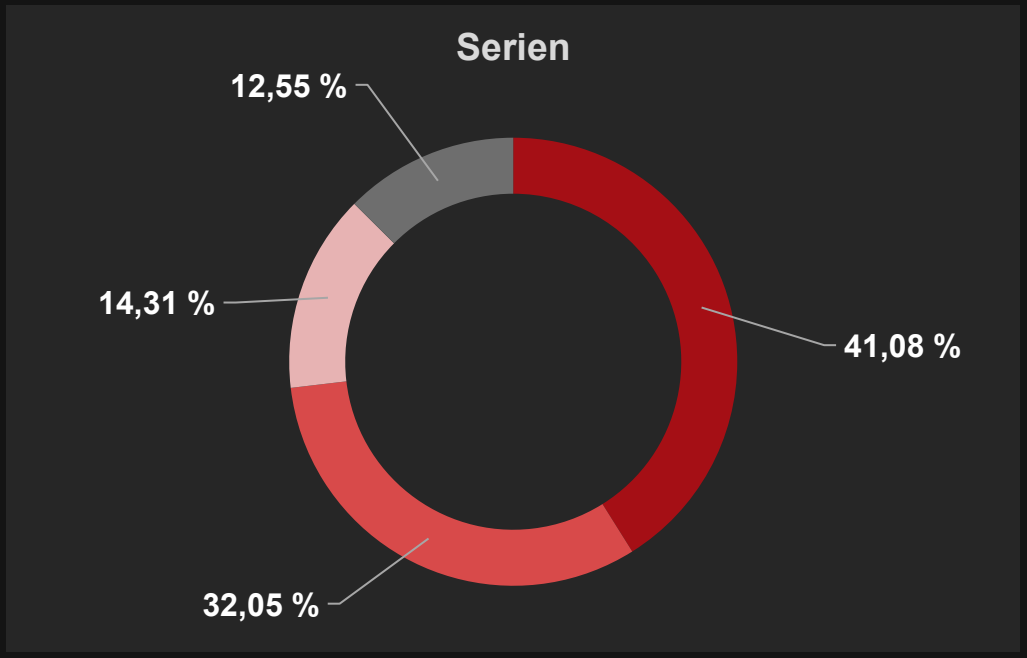

Erwachsene | Jugend / Familie | Kinder / Familie | Unbekannt / Sonstige

Serien sind deutlich klarer auf Erwachsene und Jugendliche ausgerichtet, während Filme einen hohen Anteil nicht eindeutig zuordenbarer Altersfreigaben aufweisen.

Altersfreigaben wurden mit CASE WHEN in vier Zielgruppenklassen zusammengefasst.

Limitationen

Einordnung der Ergebnisse

Fehlende Werte

Nicht alle Attribute sind für alle Titel vollständig vorhanden

Mehrfachzuordnungen

Genres und Länder können mehrfach pro Titel auftreten

IMDb-Abdeckung

Bewertungen liegen nicht für jeden Titel vor

Statischer Datensatz

Die Analyse basiert auf einem Snapshot und nicht auf Live-Daten

Die Ergebnisse sind belastbar, müssen aber im Kontext der Datenbasis interpretiert werden.

Fazit

Zentrale Erkenntnisse aus Modellierung und SQL-Analyse des Netflix-Datensatzes

Datenmodell aufgebaut

Bereinigung, Normalisierung und SQL-Struktur umgesetzt

Trends und Ausreißer analysiert

Laufzeiten, Staffeln, Bewertungen und Zielgruppen ergänzen das Bild

Katalogstruktur sichtbar gemacht

Filme, Genres und Länder zeigen klare Schwerpunkte

SQL als Analysewerkzeug genutzt

Views, Aggregationen und CASE WHEN lieferten nachvollziehbare Erkenntnisse

Die Analyse zeigt, wie aus Rohdaten durch Modellierung und SQL-Auswertung klare und fachlich interpretierbare Erkenntnisse gewonnen werden können.

SQL-Abschlussprojekt
Nicole Kaufmann