Thema : Olist E-Commerce Dataset
Fokus: Datenmodellierung, relationale Datenbanken, Datenanalyse

Lade dir anschließend den Datensatz hier herunter:
https://github.com/olist/work-at-olist-data

Bei dem Datensatz handelt es sich um reale E-Commerce-Daten der brasilianischen Plattform „Olist“. Der Datensatz enthält ca. 100.000 Bestellungen aus den Jahren 2016–2018 und umfasst u. a. Informationen zu Kunden, Bestellungen, Produkten, Verkäufern, Zahlungen und Bewertungen. ()

Die Daten liegen in mehreren CSV-Dateien vor und bilden gemeinsam eine relationale Datenbank ab.

Beantworte anhand der Datenbank folgende Fragestellungen:

1. Wie sind die Tabellen miteinander verbunden? Stelle die Beziehungen zwischen den Tabellen dar (inkl. Primär- und Fremdschlüssel).
2. Gibt es Auffälligkeiten oder Probleme im Datenmodell? (z. B. Redundanzen, unklare Zuordnungen)
3. Wie viele Bestellungen wurden insgesamt durchgeführt?
4. Welche Produktkategorien werden am häufigsten verkauft?
5. Welche Kunden haben die meisten Bestellungen aufgegeben?
6. Welche Verkäufer erzielen den höchsten Umsatz?
7. Welche Zahlungsmethoden werden am häufigsten verwendet?
8. Wie lange dauern Lieferungen im Durchschnitt?
9. Gibt es einen Zusammenhang zwischen Lieferzeit und Bewertung?
10. Welche Produkte oder Kategorien haben die besten bzw. schlechtesten Bewertungen?
11. Wie entwickeln sich die Bestellungen über die Jahre 2016–2018?
12. Gibt es Fälle, in denen Bestellungen problematisch verlaufen sind (z. B. lange Lieferzeiten, schlechte Bewertungen)?

Es sind weitere Fragestellungen möglich.
Untersuche den Datensatz eigenständig und finde mindestens drei zusätzliche interessante Erkenntnisse mit Mehrwert.

(Optional: Erstelle Views für verschiedene Benutzerrollen oder Anwendungsfälle.)

Bereite deine Ergebnisse in einer Präsentation (15–20 Minuten) auf.
Stelle dabei insbesondere die Struktur der Datenbank, deine SQL-Abfragen sowie deine wichtigsten Erkenntnisse dar.

Viel Erfolg!

Thema 2: Synthetic E-Commerce Relational Dataset
Fokus: Datenmodellierung, relationale Datenbanken, Datenanalyse

Lade dir den Datensatz hier herunter:
https://www.kaggle.com/datasets/naelaqel/synthetic-e-commerce-relational-dataset

Bei dem Datensatz handelt es sich um synthetisch erzeugte E-Commerce-Daten, die eine realistische E-Commerce-Umgebung simulieren.
Die Daten enthalten Informationen zu Kunden, Produkten, Bestellungen, Bestellpositionen und Produktbewertungen.

Importiere die CSV-Dateien in eine neue PostgreSQL-Datenbank und verknüpfe die Tabellen mittels geeigneter Schlüssel.

Analysiere die Datenbank und beantworte folgende Fragestellungen:

1. Liste alle Tabellen auf und dokumentiere für jede Tabelle:

- Primärschlüssel
- Fremdschlüssel
- kurze Beschreibung des Inhalts

2. Erstelle ein **ER-Diagramm**, das die Beziehungen zwischen den Tabellen darstellt.
3. Wie viele Kunden gibt es insgesamt?
   Wie viele Produkte gibt es insgesamt?
4. Welche Produktkategorien existieren und wie viele Produkte enthält jede Kategorie?
5. Wie viele Bestellungen wurden insgesamt aufgegeben?
   Wie viele Bestellpositionen gibt es insgesamt?
6. Welche Kunden haben die meisten Bestellungen aufgegeben?
   Welche Kunden haben den höchsten Gesamtumsatz generiert?
7. Welche Produkte wurden am häufigsten bestellt?
   Welche Produkte generieren den höchsten Umsatz?
8. Analysiere die Lieferländer:

- Wie verteilen sich die Bestellungen auf die Versandländer?

9. Analysiere die Zahlungsmethoden:

- Welche Zahlungsmethode wird am häufigsten genutzt?

10. Analysiere die Produktbewertungen:

- Welche Produkte haben die höchsten bzw. niedrigsten Durchschnittsbewertungen?
- Gibt es Produkte mit sehr wenigen Bewertungen, aber hoher Bestellmenge?

11. Gibt es zeitliche Trends:

- Wie entwickeln sich die Bestellungen über die Zeit (z. B. nach Monat oder Quartal)?

12. Finde **mindestens 3 eigene interessante Erkenntnisse**, die über die oben genannten Fragen hinausgehen.

(Optional: Erstelle Views für bestimmte Rollen oder Zwecke, z. B. „Top 10 Produkte nach Umsatz“, „Kunden mit den meisten Bestellungen“)

Bereite deine Ergebnisse in einer Präsentation (15–20 Minuten) auf, in der du insbesondere die Struktur der Datenbank, zentrale SQL-Abfragen und deine wichtigsten Erkenntnisse präsentierst.

Viel Erfolg!

Thema 3: Logistics Operations Database
Fokus: Datenmodellierung, relationale Datenbanken, Datenanalyse

Lade dir den Datensatz „Logistics Operations Database“ von Kaggle herunter:
https://www.kaggle.com/datasets/yogape/logistics-operations-database (Kaggle)

Bei diesem Datensatz handelt es sich um synthetisch erzeugte Informationen zu Logistik- und Transportprozessen.
Die Daten decken typischerweise Aktivitäten von Fahrern, Fahrzeugen, Sendungen, Depots und Operationen ab.

Importiere alle CSV-Dateien in eine neue PostgreSQL-Datenbank und verknüpfe die Tabellen mittels geeigneter Schlüssel.

Analysiere die Datenbank und beantworte die folgenden Fragestellungen:

1. Liste alle Tabellen auf und beschreibe für jede Tabelle:

- Primärschlüssel
- Fremdschlüssel
- kurze inhaltliche Beschreibung

2. Erstelle ein **ER-Diagramm**, das alle Tabellen und ihre Beziehungen zeigt.
3. Wie viele Fahrer, Fahrzeuge und Sendungen sind im Datensatz enthalten?
4. Welche Depots oder Standorte sind im Datensatz vorhanden und wie viele Sendungen sind jedem Depot zugeordnet?
5. Welche Fahrzeuge wurden am meisten eingesetzt (z. B. basierend auf Anzahl der zugeordneten Sendungen)?
6. Welche Fahrer haben die höchste Anzahl an Lieferungen abgeschlossen?
7. Welche Transportstrecken oder Routen (z. B. Start- und Zielorte) kommen am häufigsten vor?
8. Analysiere die durchschnittliche Lieferzeit:

- Vergleiche Lieferzeiten zwischen verschiedenen Depots oder Regionen

9. Gibt es Abhängigkeiten zwischen Sendungsgröße/-gewicht und Transportdauer oder Kosten?
10. Welche Fahrzeuge oder Fahrer zeigen besonders hohe oder niedrige Effizienz-KPI (z. B. Transportzeit pro Entfernungseinheit, Kosten pro Sendung)?

11. Identifiziere mindestens **3 weitere interessante betriebswirtschaftliche Muster oder Fragestellungen**, die über die obenstehenden hinausgehen.

    (Optional: Erstelle Views für typische Managementrollen, z. B. „Top Fahrer nach Lieferzeit“, „Kosten je Depot“, „Effizienz je Fahrzeugtyp“.)

Bereite deine Ergebnisse in einer Präsentation (15–20 Minuten) auf.
Stelle dabei insbesondere die Struktur des Datenbankschemas, deine SQL-Abfragen und deine wichtigsten Ergebnisse bzw. Erkenntnisse vor.

Viel Erfolg!

Thema 4: Verkehrsunfalldatenbank
Fokus: Datenmodellierung, relationale Datenbanken, Datenanalyse

Lade den Verkehrsunfalldatensatz herunter (z. B. Open-Data des jeweiligen Landes oder Stadt).
Importiere die CSV-Dateien in eine neue PostgreSQL-Datenbank und verknüpfe die Tabellen sinnvoll miteinander.

Analysiere die Datenbank und beantworte folgende Fragestellungen:

1. Liste alle Tabellen auf und dokumentiere für jede Tabelle:

- Primärschlüssel
- Fremdschlüssel
- kurze inhaltliche Beschreibung

2. Erstelle ein **ER-Diagramm**, das alle Tabellen und ihre Beziehungen darstellt.
3. Wie viele Unfälle sind im Datensatz enthalten?
   Wie viele beteiligte Fahrzeuge und Personen gibt es insgesamt?
4. Welche Unfallarten treten am häufigsten auf (z. B. Auffahrunfall, Abbiegeunfall, Zusammenstoß)?
5. Welche Verkehrsmittel (PKW, LKW, Motorrad, Fahrrad, Fußgänger) sind am häufigsten in Unfälle verwickelt?
6. Analysiere die Schwere der Unfälle:

- Wie viele Unfälle führten zu Personenschäden?
- Wie viele Unfälle führten zu Todesfällen?

7. Welche Orte oder Straßenabschnitte weisen die höchste Unfallhäufigkeit auf?
8. Gibt es zeitliche Muster:

- Unfälle nach Wochentag, Uhrzeit oder Monat
- Unterschiede bei Tag/Nacht oder Wetterbedingungen

9. Analysiere den Zusammenhang zwischen Unfallart und Unfallfolgen (z. B. Schwere, Verletzungen, Fahrzeuge beteiligt).
10. Finde mindestens **3 weitere interessante Erkenntnisse**, z. B. regionale Muster, Risikogruppen, Auffälligkeiten bei Fahrzeugtypen oder Straßenzustand.

    (Optional: Erstelle Views, z. B. „Unfälle nach Ort“, „Top 10 Straßen mit den meisten Unfällen“, „Unfälle nach Fahrzeugtyp und Schwere“)

Bereite deine Ergebnisse in einer Präsentation (15–20 Minuten) auf.
Stelle dabei insbesondere die Datenbankstruktur, zentrale SQL-Abfragen und deine wichtigsten Erkenntnisse dar.

Viel Erfolg!

Thema 5: Coffee Sales Analysis
Fokus: Datenmodellierung, Datenbankabfragen, Datenanalyse

Lade dir den Datensatz „Coffee Analisys Project“ herunter:
https://www.kaggle.com/datasets/ahmedmohamedibrahim1/coffee-analisys-project
(Kaggle)

Bei diesem Datensatz handelt es sich um Verkaufs- und Transaktionsdaten eines Kaffee-Shops oder einer Café-Kette.
Die Daten enthalten u. a. Informationen zu Kaffee-Produkten, Kaufdatum und -uhrzeit, Zahlungsart und Verkaufserlösen.
Importiere die CSV-Datei(en) in eine PostgreSQL-Datenbank.

Beantworte anhand der Datenbank folgende Fragestellungen:

1. Welche Spalten enthält die(n) Tabelle(n) im Datensatz?
   Gib für jede(n) Tabelle/Datentabelle die Spaltennamen und Datentypen an.
2. Bestimme, ob ein Primärschlüssel in der(n) Tabelle(n) vorhanden ist.
   Falls nicht vorhanden: Definiere eine geeignete Spalte oder Kombination als Primärschlüssel.
3. Gibt es Redundanzen oder Unstimmigkeiten in den Daten (z. B. doppelte Zeilen, falsche Werte, fehlende Daten)?
   Fasse kurz zusammen, welche Daten-Qualitätsprobleme du findest.
4. Wie viele Transaktionen/Käufe sind insgesamt im Datensatz enthalten?
5. Welche Kaffeesorten/Produkte werden am häufigsten verkauft?
6. Welches Kaffee-Produkt bringt den höchsten Gesamtumsatz?
7. Wie verteilt sich der Umsatz über die Wochentage?
   Welcher Wochentag erzielt den höchsten Umsatz?
8. Wie verteilt sich der Umsatz über Tageszeiten (z. B. Morgen, Nachmittag, Abend) bzw. über einzelne Stunden?
9. Welche Zahlungsmethoden werden wie häufig genutzt und wie unterscheiden sie sich im durchschnittlichen Verkaufsbetrag?
10. Welche Kaffee-Produkte verkaufen sich besonders gut bzw. besonders schlecht in Bezug auf Anzahl und Umsatz?
11. Gibt es signifikante saisonale Muster oder Trends im Verkaufsverhalten (z. B. pro Monat oder über den Zeitraum)?

12. Identifiziere mindestens **3 weitere eigenständige interessante Erkenntnisse**, die über die oben stehenden Fragen hinaus gehen (z. B. Kunden- oder Zeitverhalten, Produktmuster, Peaks in der Nachfrage).

    (Optional: Erstelle Views, die für bestimmte Zwecke nützlich sind, z. B. „Top-5-Produkte nach Umsatz“, „Umsatz je Wochentag“, „Umsatz je Zahlungsart“.)

Bereite deine Ergebnisse in einer Präsentation (15–20 Minuten) auf.
Stelle dabei insbesondere die Struktur deines Datenmodells, zentrale SQL-Abfragen und deine wichtigsten Erkenntnisse dar.

Viel Erfolg!

Thema 6: Pokémon Trading Card Game-Datenbank
Fokus: Datenmodellierung, relationale Datenbankabfragen, Datenanalyse

Lade dir den Datensatz „Pokémon TCG All Cards 1999-2023“ herunter:
https://www.kaggle.com/datasets/adampq/pokemon-tcg-all-cards-1999-2023

Bei diesem Datensatz handelt es sich um eine Sammlung aller Pokémon-TCG-Karten, die von 1999 bis 2023 veröffentlicht wurden.
Der Datensatz enthält u. a. Informationen zu Kartennamen, Typen, Seltenheit, HP, Schaden, Kosten, Sets und Fähigkeiten.

Importiere die(n) CSV-Datei(en) in eine PostgreSQL-Datenbank und verknüpfe die Tabellen mittels geeigneter Schlüssel, falls mehrere Tabellen vorliegen.

Beantworte anhand der Datenbank folgende Fragestellungen:

1. Welche Tabellen bzw. Datentabellen enthält der Datensatz?
   Liste für jede Tabelle die Spaltennamen, Datentypen und kurz, welche Informationen sie enthält.
2. Identifiziere einen geeigneten **Primärschlüssel** für die(n) Tabelle(n).
   Falls kein expliziter Primärschlüssel vorhanden ist, definiere einen geeigneten eindeutigen Schlüssel.
3. Wie viele Pokémon-TCG-Karten sind insgesamt im Datensatz enthalten?
4. Welche Pokémon-Kartentypen (z. B. Feuer, Wasser, Pflanze etc.) kommen wie häufig vor?
5. Analysiere die Seltenheiten:

- Welche Seltenheitsstufen existieren?
- Wie viele Karten gehören zu jeder Seltenheitsstufe?

6. Wie verteilen sich die Karten über die verschiedenen Jahre oder Sets?
7. Gibt es bestimmte Kartentypen, die im Durchschnitt höhere HP-Werte haben?
   Führe mindestens eine vergleichende Analyse zwischen Typen durch.
8. Welche Pokémon-Karten haben den höchsten Schaden (Attack Power) und welche den niedrigsten?
9. Untersuche Kosten-Effizienz:

- Gibt es Zusammenhänge zwischen Kartenkosten und Schaden?
- Welche Kartentypen erzeugen relativ hohen Schaden bei niedrigen Kosten?

10. Welche Sets oder Zeitperioden brachten die meisten Karten hervor?

11. Identifiziere mindestens **3 weitere selbst gewählte interessante Fragestellungen** und beantworte sie – z. B. Kombinationen von Typen, Entwicklungen, Fähigkeiten, HP-Verteilungen, seltene Muster etc.

    (Optional: Erstelle Views, die für typische Auswertungen nützlich sind, z. B. „Top-10 Karten nach Schaden“, „Kartentypen nach HP-Durchschnitt“, „Set-Statistiken“.)

Bereite deine Ergebnisse in einer Präsentation (15–20 Minuten) auf.
Präsentiere insbesondere die Struktur deines Datenmodells, wichtige SQL-Abfragen und deine zentralen Erkenntnisse.

Viel Erfolg!

Thema 7 : Video Game Dataset – Multidimensional
Fokus: Datenmodellierung, relationale Datenbanken, Datenanalyse

Lade dir den Datensatz **„Video Game Dataset – Multidimensional“** von Kaggle herunter:
https://www.kaggle.com/datasets/gabrigoncam/video-game-dataset-multidimensional (Kaggle)

Bei diesem Datensatz handelt es sich um eine umfangreiche Sammlung von Videospiel-Metadaten über viele Jahre, die u. a. Informationen zu Spielen, Genres, Plattformen, Entwicklern, Publishern, Bewertungen und Verkaufszahlen enthalten.

Importiere alle CSV-Dateien in eine PostgreSQL-Datenbank und verknüpfe die Tabellen mithilfe geeigneter Schlüssel zu einem konsistenten relationalen Schema.

Beantworte anhand der Datenbank folgende Fragestellungen:

1. Liste alle Tabellen im Datensatz auf und dokumentiere für jede Tabelle:

- Primärschlüssel
- Fremdschlüssel
- kurze inhaltliche Beschreibung

2. Erstelle ein **ER-Diagramm**, das die Beziehungen zwischen den Tabellen darstellt.
3. Wie viele Videospiele enthält der Datensatz insgesamt?
4. Welche Spiele wurden auf den meisten unterschiedlichen Plattformen veröffentlicht?
5. Analysiere die Verteilung der Genres:

- Welche Genres sind am häufigsten vertreten?
- Welche Genres erzielen im Durchschnitt die höchsten Bewertungen?

6. Welche Plattformen dominieren den Markt hinsichtlich Anzahl der Spiele und Bewertungen?
7. Bestimme die Spiele mit den höchsten und niedrigsten Gesamtbewertungen bzw. Verkaufszahlen.
8. Untersuche zeitliche Trends:

- Wie haben sich Anzahl und Bewertungen der Spiele über die Jahre verändert?

9. Analysiere den Einfluss von Publishern und Entwicklern:

- Welche Publisher bringen die meisten Spiele heraus?

- Welche Entwickler haben im Durchschnitt die höchsten Bewertungen?

10. Gibt es Zusammenhänge zwischen Genre, Plattform und Bewertung (z. B. bestimmte Genres auf bestimmten Plattformen mit besonders hohen Bewertungen)?

11. Identifiziere mindestens **3 zusätzliche selbst gewählte interessante Erkenntnisse**, die über die obenstehenden Fragen hinausgehen (z. B. Analyse von Trends, Nischen-Genres, Plattform-Spezifika oder Release-Strategien).

    (Optional: Erstelle Views für typische Management- oder Analysezwecke, z. B. „Top-10 Spiele nach Bewertung“, „Genres mit höchsten Durchschnittsbewertungen“, „Publisher-Statistiken“)

Bereite deine Ergebnisse in einer Präsentation (15–20 Minuten) auf.
Stelle dabei insbesondere die Struktur deines Datenmodells, zentrale SQL-Abfragen sowie deine wichtigsten Erkenntnisse dar.

Viel Erfolg!

Thema 8 : Gaming Profiles 2025 (Steam, PlayStation, Xbox)
Fokus: Datenmodellierung, relationale Datenbanken, Datenanalyse

Lade dir den Datensatz „Gaming Profiles 2025 (Steam, PlayStation, Xbox)“ herunter:
https://www.kaggle.com/datasets/artyomkruglov/gaming-profiles-2025-steam-playstation-xbox

Bei diesem Datensatz handelt es sich um Gaming-Profilergebnisse von Spielern auf verschiedenen Plattformen (z. B. Steam, PlayStation, Xbox).
Die Daten enthalten vermutlich Informationen zu Spielern, Plattformaccounts, gespielten Titeln, Spielzeiten, Genres, Bewertungen und weiteren Gaming-Aktivitätsmetriken.

Importiere alle CSV-Dateien in eine neue PostgreSQL-Datenbank und verknüpfe die Tabellen mittels geeigneter Schlüssel.

Beantworte anhand der Datenbank folgende Fragestellungen:

1. Welche Tabellen enthält der Datensatz?
   Für jede Tabelle dokumentiere:

- Primärschlüssel
- Fremdschlüssel
- kurze inhaltliche Beschreibung

2. Erstelle ein **ER-Diagramm**, das die Beziehungen zwischen den Tabellen darstellt.
3. Wie viele Spielerprofile enthält der Datensatz insgesamt?
4. Wie verteilen sich die Spieler auf die Plattformen (z. B. Steam, PlayStation, Xbox)?
5. Welche Spiele oder Titel werden am häufigsten über alle Plattformen gespielt?
6. Wie unterscheiden sich die durchschnittlichen Spielzeiten pro Spieler zwischen den Plattformen?
7. Untersuche die Genre-Beliebtheit:

- Welche Genres werden am häufigsten gespielt?
- Welche Genres zeigen im Durchschnitt die längsten Spielzeiten?

8. Analysiere plattformübergreifende Unterschiede:

- Spielen Steam-User andere Titel als PlayStation- oder Xbox-User?
- Gibt es Titel, die nur auf einer Plattform dominieren?

9. Finde heraus, welche Spieler die höchsten kumulierten Spielzeiten erzielen – nach Plattform geordnet.
10. Gibt es Zusammenhänge zwischen Spielzeit und anderen Attributen (z. B. Genre, Bewertung, Kaufdatum)?
11. Identifiziere mindestens **3 zusätzliche selbst gewählte interessante Fragestellungen** (z. B. Unterschiede in Spielverhalten nach Genre, Spielzeit-Cluster, Plattform-Kombinationen) und beantworte sie.

    (Optional: Erstelle Views, die für typische Auswertungen sinnvoll sind, z. B. „Top-10-Spiele nach Spielzeit“, „Spielzeiten je Plattform“, „Genre-Beliebtheitsranking“.)

Bereite deine Ergebnisse in einer Präsentation (15–20 Minuten) auf.
Stelle dabei insbesondere die Struktur des Datenbankschemas, zentrale SQL-Abfragen und deine wichtigsten Erkenntnisse dar.

Viel Erfolg!

Thema 9 : Synthetic Banking Dataset (CSV, SQL, SQLite)
Fokus: Datenmodellierung, relationale Datenbanken, Datenanalyse (Finance)

Lade dir den *Synthetic Banking Dataset* von Kaggle herunter:
https://www.kaggle.com/datasets/akrambelha/synthetic-banking-dataset-csv-sql-sqlite (Kaggle)

Bei diesem Datensatz handelt es sich um eine groß angelegte synthetische Banking-Datenbank, die typische Bankdaten simuliert, darunter Kontoinformationen, Transaktionen, Kundenprofile, Kontostände und weitere finanzielle Aktivitäten. (Kaggle)

Importiere alle relevanten CSV-Dateien in eine PostgreSQL-Datenbank und verknüpfe die Tabellen mittels geeigneter Schlüssel zu einem konsistenten relationalen Schema.

Beantworte anhand der Datenbank folgende Fragestellungen:

1. Liste alle Tabellen auf und dokumentiere für jede Tabelle:

- Primärschlüssel
- Fremdschlüssel
- kurze inhaltliche Beschreibung

2. Erstelle ein **ER-Diagramm**, das alle Tabellen und ihre Beziehungen darstellt.
3. Wie viele Kunden bzw. Kontoinhaber enthält der Datensatz insgesamt?
4. Wie viele Bankkonten sind im Datensatz vorhanden und wie verteilen sie sich nach Kontotypen (z. B. Girokonto, Sparkonto, Kreditkonto)?
5. Wie viele Transaktionen wurden insgesamt durchgeführt und wie verteilen sie sich nach Transaktionstypen (z. B. Einzahlung, Auszahlung, Überweisung)?
6. Welche Kunden haben die höchste Anzahl an Transaktionen?
   Welche Kunden generieren den höchsten Transaktionswert (Summe aller Transaktionsbeträge)?
7. Analysiere Kontostände:

- Welche Konten haben die höchsten Guthaben?
- Welche Konten weisen negative Salden auf (falls vorhanden)?

8. Untersuche das Transaktionsverhalten über die Zeit:

- Gibt es zeitliche Muster (z. B. nach Monat, Quartal oder Jahr)?

9. Analysiere Zusammenhänge zwischen Kontotypen, Transaktionsvolumen und Kundensegmenten (falls Segmentdaten vorhanden).

10. Identifiziere typische Risiko- oder Merkmalsmuster:

- Gibt es Kunden mit ungewöhnlich hohem Transaktionsvolumen bei geringem Kontostand?
- Gibt es saisonale Peaks in bestimmten Transaktionstypen?

11. Identifiziere mindestens **3 eigenständige, interessante Erkenntnisse**, die über die obenstehenden Fragestellungen hinausgehen (z. B. Muster in Ausgabenverhalten, Merkmale nach Kundengruppen, Vergleich zwischen Kontotypen).

    (Optional: Erstelle Views für typische Finance-Analysen, z. B. „Top-10 Transaktionskunden“, „Kontostände nach Kundengruppe“, „Transaktionsvolumen nach Monat“.)

Bereite deine Ergebnisse in einer Präsentation (15–20 Minuten) auf.
Stelle dabei insbesondere die Struktur deines Datenbankschemas, zentrale SQL-Abfragen und deine wichtigsten Erkenntnisse dar.

Viel Erfolg!

Thema 10: Netflix Movies and TV Shows Database
Fokus: Datenmodellierung, relationale Datenbanken, Datenanalyse

Lade dir den Datensatz *Netflix Movies and TV Shows* von GitHub herunter:
https://github.com/Arpita-deb/netflix-movies-and-tv-shows/tree/main

Importiere alle relevanten CSV-Dateien in eine PostgreSQL-Datenbank und verknüpfe die Tabellen mittels geeigneter Schlüssel.

Beantworte anhand der Datenbank folgende Fragestellungen:

1. Liste alle Tabellen auf und beschreibe für jede:

- Primärschlüssel
- Fremdschlüssel
- kurze inhaltliche Beschreibung

2. Erstelle ein **ER-Diagramm**, das die Beziehungen zwischen den Tabellen darstellt.
3. Wie viele Inhalte (Filme und Serien) sind insgesamt im Datensatz enthalten?
   Wie viele davon sind Filme und wie viele TV-Shows?
4. Welche Genres kommen im Datensatz am häufigsten vor?
5. Wie verteilen sich die Inhalte über die Jahre (z. B. Veröffentlichungen je Jahr)?
6. Welche Regisseure oder Showrunner haben die meisten Inhalte auf Netflix produziert?
7. Analysiere die Länge/Dauer:

- Welche Filme sind am längsten (Laufzeit)?
- Welche Serien haben die meisten Staffeln oder Episoden (sofern Daten vorhanden)?

8. Untersuche die Genre-Beliebtheit in Bezug auf Veröffentlichungsjahr:

- Gibt es Trends bei Genres über die Zeit?

9. Welche Titel enthalten bestimmte Schlüsselwörter im Titel oder in der Beschreibung (z. B. „Love“, „War“, „Adventure“)?
   Fasse gruppiert nach Keyword.
10. Identifiziere mindestens **3 weitere interessante Fragestellungen** und beantworte sie (z. B. Kombinationen von Genres, Entwicklung von Genre-Shares über Jahren, Verhältnis von Filmen zu Serien pro Jahr, Ähnlichkeit zwischen Genres/Produzenten).

(Optional: Erstelle Views, die für typische Analysen sinnvoll sind, z. B. „Top-10 Genres nach Anzahl“, „Inhalte je Jahr“, „Inhalte nach Dauer“.)

Bereite deine Ergebnisse in einer Präsentation (15–20 Minuten) auf.
Präsentiere dabei besonders die Struktur deines Datenmodells, zentrale SQL-Abfragen und deine wichtigsten Erkenntnisse.

Viel Erfolg!

Eigenes Thema vorschlagen (optional)

Falls dein Interessensgebiet oder gewünschter Datensatz nicht in den vorgegebenen Themen enthalten ist, kannst du ein eigenes Thema vorschlagen.

Voraussetzungen für die Freigabe:

1. Der Datensatz muss **relational** aufgebaut sein oder sich in eine relationale Struktur überführen lassen.
2. Die Daten müssen für die Analyse **zugänglich** sein (CSV, SQL, SQLite oder eine andere kompatible Form).
3. Die Datenmenge sollte **handhabbar** sein (nicht mehrere Millionen Zeilen ohne Möglichkeit der Aggregation).
4. Du musst vorab eine kurze **Beschreibung deines Datensatzes und der geplanten Analysen** einreichen.
    - Quelle des Datensatzes
    - Anzahl und Art der Tabellen
    - Beispielhafte Fragestellungen / Analyseideen

Nach Prüfung und Freigabe durch die Lehrperson kannst du dein eigenes Thema für das Projekt verwenden.

Hinweis: Auch bei eigenen Themen gelten die gleichen Anforderungen wie für die vorgegebenen Datensätze:

- Relationale Modellierung / Datenbankstruktur
- SQL-Abfragen zur Beantwortung relevanter Fragen
- Analyse & Präsentation deiner Erkenntnisse (15–20 Minuten)